

# LOKALISATION MOBILER ROBOTER MIT ODOMETRIE UND BILDVERARBEITUNG IN EINER THEATERINSTALLATION

## M A S T E R A R B E I T

eingereicht am

23.09.2013

bei

Prof. Dr.-Ing. Udo Frese

Universität Bremen

von

Josef F. Hiller

Matr. Nr: 2055491

Osterstr 79

28199 Bremen



# Zusammenfassung

**Schlagwörter:** abc, def, xyz



# Erklärung

Ich versichere, dass ich die vorliegende Arbeit selbstständig angefertigt und mich fremder Hilfe nicht bedient habe. Alle Stellen, die wörtlich oder sinngemäß veröffentlichtem oder unveröffentlichtem Schrifttum entnommen sind, habe ich als solche kenntlich gemacht.

Bremen, 23.09.2013

---

Josef F. Hiller



# Inhaltsverzeichnis

<b>Zusammenfassung</b>	<b>iii</b>
<b>Erklärung</b>	<b>v</b>
<b>Abbildungsverzeichnis</b>	<b>ix</b>
<b>1 Einleitung</b>	<b>1</b>
1.1 Ziel und Aufgabenstellung der Arbeit . . . . .	1
1.2 Gliederung . . . . .	3
<b>2 Grundlagen</b>	<b>5</b>
2.1 Der Roboter . . . . .	5
2.2 Bühneninstallation . . . . .	6
2.3 Lokalisation . . . . .	7
2.3.1 Übersicht gängiger Verfahren . . . . .	8
2.3.2 Der Partikelfilter . . . . .	9
2.4 Bildverarbeitung . . . . .	11
<b>3 Lokalisierung mittels Bildverarbeitung</b>	<b>13</b>
3.1 Bitmuster . . . . .	13
3.2 Partikelfilter . . . . .	14
3.2.1 Zustandsraum . . . . .	14
3.2.2 Dynamikmodell . . . . .	15
3.2.3 Messmodell . . . . .	16
3.2.4 Initialisierung . . . . .	18
3.2.5 Schätzung aus Partikeln berechnen . . . . .	19
3.3 Musterbewertung . . . . .	19
3.3.1 Spezialfall: Projektion ergibt keine Bildpunkte . . . . .	19
3.3.2 Mindestanzahl auswertbarer Bildpunkte . . . . .	22
3.3.3 Bestimmung mittlerer Weiß- und Schwarzwerte . . . . .	22

3.3.4	Bewertungskriterium . . . . .	22
3.4	Parameter einstellen . . . . .	23
<b>4</b>	<b>Die Simulationssoftware</b>	<b>27</b>
4.1	Koordinatensysteme . . . . .	27
4.2	Die Szene . . . . .	28
4.3	Messen in der Simulation . . . . .	30
4.3.1	Messwerte der Encoder . . . . .	31
4.3.2	Messabweichung der Encoder . . . . .	31
4.3.3	Bilder der Kamera . . . . .	33
4.4	Einstellungen . . . . .	34
<b>5</b>	<b>Versuche in der Simulation</b>	<b>37</b>
5.1	Versuche zur Genauigkeit des Messmodells . . . . .	37
5.2	Verwendete Fahrkurven . . . . .	39
5.3	Versuche zur Bildaufnahmefrequenz . . . . .	41
5.4	Versuche zum Einfluss von Menschen auf der Bühne . . . . .	45
<b>6</b>	<b>Fazit und Ausblick</b>	<b>49</b>
<b>A</b>	<b>Abkürzungsverzeichnis</b>	<b>I</b>
<b>B</b>	<b>Literaturverzeichnis</b>	<b>III</b>
<b>C</b>	<b>Anhang</b>	<b>V</b>



# Abbildungsverzeichnis

1.1	Roboter und Besucher auf der EPKOT . . . . .	2
1.2	Roboter vor Lichtwand auf der EPKOT . . . . .	2
2.1	Nahaufnahme eines der Roboter . . . . .	5
2.2	Bühnenmodell . . . . .	6
3.1	Bitmuster der Lichtwände . . . . .	13
3.2	Bild und Plot zur Bewertung des Minimalscores . . . . .	21
4.1	Koordinatensysteme in der Simulation . . . . .	27
4.2	Simulierte Szene . . . . .	29
4.3	OpenGL frustum . . . . .	33
5.1	Antwort des Messmodells im Zustandsraum auf ein gegebenes Bild . .	38
5.2	Antwort des Messmodells bei $x=0.0$ . . . . .	40
5.3	Fahrkurven oben Loop Anticlockwise, und unten Loop Clockwise . .	42
5.4	Fahrkurven oben Schlangenlinien, unten schräge Ellipse . . . . .	44
5.5	Mittlerer Abstand über Bildaufnahmefrequenz . . . . .	45
5.7	Mögliche Positionen von Personen . . . . .	45
5.6	Gemittelter langer Durchmesser der Unsicherheits-Ellipse über ver- schiedene Bildaufnahmefrequenzen mit vier verschiedenen Fahrkurven.	46
5.8	toller text . . . . .	47
C.1	code 93 Tabelle . . . . .	VI



# 1 Einleitung

In dieser Arbeit soll mit Hilfe einer Simulation untersucht werden, wie gut sich Kameras bei der Standortbestimmung in mobilen Robotern einsetzen lassen. Anlass dieser Arbeit war eine Anfrage der Künstlergruppe *Beobachter der Bediener von Maschinen* (BBM), die schon bei mehreren Performances<sup>1</sup> mobile Roboter eingesetzt hat. Diese fahren zum Teil in einer Choreografie über die Bühne. Um sie dabei eine vorgegebene Figur fahren zu lassen, muss der Steuerung bekannt sein, wo sich ein Roboter auf der Bühne aufhält. Eine solche Lokalisation war in der Vergangenheit für BBM sehr aufwendig. Aus diesem Grund interessierte sich die Künstlergruppe für eine Lokalisierungslösung, welche möglichst ohne weitere Spezialhardware und geringem Installationsaufwand vor Ort auskommt. Der Ansatz, der daraus entstand, war: die Kameras, die bereits an jedem der Roboter verbaut waren, zu nutzen, um markante Muster in der Bühneninstallation zu erkennen. Zusammen mit Messungen der Odometrie (sie beschreibt wie die Räder eines Roboters sich bei Bewegung drehen) soll die Position und Orientierung berechnet werden. Ein Partikelfilter ist als Zustandsschätzer zu verwenden. Zu der Bühneninstallation gehören große Lichtwände, zu sehen auf Abbildung 1.1 und 1.2. Auf diesen Lichtwänden wird ein hell/dunkel Bit-Muster angezeigt, welches es mit Hilfe geeigneter Bildverarbeitungsalgorithmen und mit den Kameras zu erkennen gilt.

## 1.1 Ziel und Aufgabenstellung der Arbeit

Im Rahmen dieser Arbeit soll eine Simulationsumgebung mit Hilfe geeigneter 3D-Visualisierungs-Bibliotheken erstellt werden. Diese soll in der Lage sein, eine 3D-Szene der Bühne zu simulieren und Kamerabilder sowie Odometrie-Daten einer Roboterfahrt zu erzeugen. Des weiteren soll ein Lokisationsalgorithmus entwickelt

---

<sup>1</sup>unter Anderem:

2000 Themenpark "Wissen" der Expo 2000 Hannover

2010 Joybots in der BMW-Welt

2012 EPKOT Experimental Prototype Killers of Tomorrow , Hannover

siehe auch <http://www.bbm.cfnt3.de>




Abbildung 1.1: Roboter und Besucher auf der EPKOT Quelle: <http://www.bbm.cfnt3.de>




Abbildung 1.2: Roboter vor Lichtwand auf der EPKOT Quelle: <http://www.bbm.cfnt3.de>

werden, der auf Grundlage dieser Daten die Position und Orientierung des Roboters auf der Bühne schätzen kann. Anschließend soll die Qualität dieser geschätzten Position beurteilt und mögliche Fehlerquellen diskutiert werden.

## 1.2 Gliederung

Im folgenden Kapitel soll eine kurze Übersicht über gängige Lokalisationsverfahren sowie deren Vor- und Nachteile gegeben werden. Außerdem sollen weitere Grundlagen zum besseren Verständnis der nachfolgenden Kapitel vermittelt werden. Das Kapitel *Lokalisierung mittels Bildverarbeitung* beschreibt, wie die Methoden aus den Grundlagen an das gestellte Problem angepasst wurden und wie das vorgestellte Verfahren funktioniert. Anschließend wird die Simulationssoftware vorgestellt und ihre Implementation erklärt und begründet. Insbesondere soll auf die Realitätsnähe der Simulation eingegangen werden. In Kapitel 5 beginnt die Beschreibung verschiedener Versuche, die zum Beurteilen der Lokalisationsergebnisse durchgeführt wurden. Ergebnispräsentation und -diskussion erfolgen jeweils im Anschluss an die Beschreibungen. Abschließend wird ein Ausblick zur möglichen Anwendung dieses Verfahrens gegeben, sowie mögliche Fehlerquellen und Probleme dabei. Im letzten Kapitel wird ein Fazit zu den gewonnenen Erkenntnissen dieser Arbeit gezogen.



## 2 Grundlagen

### 2.1 Der Roboter

An dieser Stelle soll kurz beschrieben werden, wie die Roboter (siehe Abbildungen 1.1, 1.2 und 2.1), die BBM einsetzt, aufgebaut sind. Sie dienen als Grundlage für die Entwicklung der Simulation. Sie besitzen zwei angetriebene Räder und mindestens ein weiteres Stützrad, welches frei drehbar ist. Die Räder können unabhängig voneinander angesteuert werden. Dazu sind pro Rad ein Servomotor mit Motorsteuerung und ein Getriebe mit Übersetzung verbaut. Zudem ist an jedem Rad ein




Abbildung 2.1: Einer der Roboter in Nahaufnahme

Drehimpulsgeber angebracht, der die Umdrehungen der Motorwelle misst. Dieser



wird im weiteren Verlauf der Arbeit mit Encoder<sup>1</sup> abgekürzt. Es gibt verschiedene Baugrößen der Roboter, wobei der Antrieb bei allen baugleich ist. Die Räder haben einen Durchmesser von  $160\text{ mm}$ , das Getriebe hat ein Übersetzungsverhältnis von 1:14,5 und die Encoder haben eine Auflösung von 2000 Ticks pro Umdrehung. Lediglich der Radstand unterscheidet sich bei den Baugrößen. Für die Simulation wird mit einem Radstand von  $700\text{ mm}$  gearbeitet.

## 2.2 Bühneninstallation




Abbildung 2.2: Ein Modell einer möglichen Bühne

Die für die Ausstellungen benötigten Bühneninstallationen waren zum Zeitpunkt der Arbeit nicht vorhanden. Sie wurden in der Simulation mit *Open Scene Graph* (OSG) nachgebildet und sind in der Abbildung 2.2 zu sehen. Die Aufnahme ist von schräg oben auf die  $12 \times 12\text{ m}$  Grundfläche gemacht worden. An drei Seiten stehen so genannte Lichtwände die  $3\text{ m}$  hoch und  $8\text{ m}$  breit sind. In der obersten Zeile wurde mit schwarzer und weißer Textur ein Bit-Muster modelliert.

---

<sup>1</sup>Nach der Englischen Bezeichnung: Incremental rotary encoder



## 2.3 Lokalisation

Die Lokalisation ist eines der Grundprobleme welches beim Einsatz von mobilen Robotern auftritt, und lässt sich gemäß [Thrun et al., 2006, S. 193] in drei Teilprobleme untergliedern:

**Position Tracking** ist die Verfolgung der Roboterposition und Orientierung bei bekannten Anfangsbedingungen mit Hilfe von Sensordaten. Dabei spielt das Dynamikmodell des Roboters sowie darin modellierte Unsicherheiten eine wichtige Rolle. Bewegt sich der Roboter von einer bekannten Position aus, wird mit dem Dynamikmodell auf Grund der Odometrie seine neue Position geschätzt. Die Unsicherheiten des Modells erzeugen dabei eine Wahrscheinlichkeitsverteilung um diese neue Position, in der sich die wahre Position befinden sollte. Ohne Messungen von weiteren Sensoren, die Rückschlüsse auf die Umgebung erlauben, würde die Positionsschätzung mit der Zeit immer ungenauer. Mit Hilfe eines Messmodells lässt sich beurteilen, ob eine Messung an einer bestimmten Position wahrscheinlich erscheint oder nicht. Dadurch lässt sich die Wahrscheinlichkeitsverteilung der Position nach einer Bewegung durch eine Messung wieder auf den Bereich, in dem der Messwert des Sensors am wahrscheinlichsten ist, eingrenzen.

**Global Localization** ist das Finden der Anfangsposition des Roboters unter allen möglichen Posen die im Szenario vorkommen können. Im Vergleich zum *Position Tracking*, bei dem es genügt, die Unsicherheit um die geschätzte neue Pose zu berücksichtigen, umfasst hier der Raum möglicher Posen ein erheblich größeres Volumen. Ein Ansatz wäre, alle möglichen Posen mit der selben Wahrscheinlichkeit anzunehmen, und mit den ersten Messungen und dem Messmodell diese auf Bereiche einzugrenzen, in denen diese Messungen mit hoher Wahrscheinlichkeit auftreten. Dies ist jedoch sehr viel aufwändiger als das *Position Tracking* und kann bei einem großen Zustandsraum sehr lange Dauern.

**Kidnapped Robot Problem** ist eine verschärfte Variante des *Global Localization* Problems. Dabei geht man davon aus, dass sich der Roboter spontan an einem anderen Ort aufhält als vom Roboter angenommen. Nun müsste die Lokalisation des Roboters wieder im gesamten möglichen Raum erfolgen, nur kann der Roboter diesen Zustand nicht feststellen. Um dieses Problem lösen zu können, müsste ein Algorithmus, parallel zum *Position Tracking*, den gesamten Zustandsraum prüfen. Bei einigen Anwendungen würde dies zu lange dauern. So wäre es auch denkbar, dass nicht der gesamte Zustandsraum für jede Messung

durchsucht wird, sondern nur Teile davon. Entweder geschähe dies systematisch, so dass nach einer gewissen Zeit ebenfalls der gesamte Zustandsraum durchsucht ist, oder durch zufällige Ziehungen aus dem Gesamtvolumen des Zustandsraums, so dass eine Wahrscheinlichkeit besteht, den wahren Zustand zu treffen.

### 2.3.1 Übersicht gängiger Verfahren

Die meisten Lösungsansätze verwenden eine Variante des Bayes-Filters<sup>2</sup>. Abhängig vom Einsatzumfeld und der verwendeten Sensoren gibt es jedoch noch andere Verfahren.

In [Seco et al., 2009] zum Beispiel werden, neben dem Bayes-Filter, drei weitere genannt: *Geometry-Based Methods*, *Minimization of the cost function* und *Fingerprint Methods* die sich in Gebäuden, unter Nutzung von elektromagnetischen Signalen, verwenden lassen. Je nach Sensorausstattung werden verschiedene Karten der Umgebung verwendet, auf denen sich der Roboter durch Auswertung von Sensormessungen lokalisieren muss. Dabei gibt es vorher angefertigte, statische Karten, die dem Roboter bereits zur Verfügung stehen, als auch Karten, die der Roboter selbstständig während der Lokalisation erstellen muss. Letzteres wird als *Simultaneous Localization and Mapping* (SLAM) Problem bezeichnet, zu dem es bereits viele Veröffentlichungen gibt (u.a.) [Thrun et al., 2006, S. 309], [Thrun, 2002], [Hertzberg et al., 2012, S. 229].

Der in Kapitel 1 erwähnte Partikelfilter ist eine Variante des Bayes-Filters. Er ist auch als *Monte Carlo Localization* (MCL) bekannt. Alternativ dazu existiert der Kalman Filter, der mit Normalverteilungen die Wahrscheinlichkeiten abbildet. Er ist in seiner Anwendbarkeit auf lineare Probleme beschränkt oder auf Linearisierung angewiesen. Er ist allerdings eines der ältesten Verfahren und damit am besten untersucht. In [Ha et al., 2012] wird er bei einem Lokalisationsproblem verwendet. Weiterhin existieren so genannte Grid-Based-Filter oder Histogram Filter. Diese teilen den Zustandsraum in so genannte Grids auf, in denen ein Wahrscheinlichkeitswert jeweils den Zustand der Region abbildet. Für bestimmte Probleme mit nur zwei Zuständen kann ein Binary Bayes Filter zum Einsatz kommen. Da in dieser Arbeit ein Partikelfilter verwendet wird, soll im folgenden Abschnitt seine Funktionsweise erläutert werden.

---

<sup>2</sup>in [Thrun et al., 2006, S. 26] beschrieben

### 2.3.2 Der Partikelfilter

#### Zustandsraum

Der Partikelfilter bildet die Wahrscheinlichkeitsverteilung des vermuteten Zustandes durch eine diskrete Menge von so genannten Partikeln ab. Ein Partikel ist dabei ein Punkt im Zustandsraum zu dem noch ein Gewichtungswert zugeordnet ist. Angenommen der Zustand wäre die Position in einem dreidimensionalen Koordinatensystem, so wäre der Zustandsraum alle möglichen Punkte in diesem Koordinatensystem. Ein Partikel in diesem Raum hätte also vier Attribute: einen X-Wert, einen Y-Wert, einen Z-Wert und einen Gewichtungswert. Im Grundzustand ist der Gewichtungswert bei allen Partikeln gleich und die räumliche Verteilung oder Häufung repräsentiert die Wahrscheinlichkeitsverteilung des vermuteten Zustandes (hier die Position im Koordinatensystem). Häuften sich die Partikel um eine Position, so wäre bei einer zufälligen Ziehung aus den Partikeln die Wahrscheinlichkeit höher, ein Partikel von dieser Position zu ziehen. Mittelt man nun über alle Partikel im Zustandsraum, so erhält man eine Position, die dem vermuteten Zustand entspricht. Dabei ist die Varianz über alle Partikel ein Maß dafür, wie zuverlässig diese Position ist.

#### Dynamikmodell

Partikelfilter nutzen für die Zustandsschätzung ein Dynamikmodell. In diesem Modell wird abgebildet, wie sich der Zustand über die Zeit verändert, z.B. durch Physikalische Gesetzmäßigkeiten oder durch eine Hilfsgröße die sich messen lässt (z.B. zurückgelegter Weg). Mit diesem Wissen, über das betrachtete System, erlaubt das Dynamikmodell eine Prognose über den nächsten Zustand abzugeben. Um das Beispiel weiter zu führen stelle man sich vor, man wolle die Position eines Satelliten, der um die Erde kreist, bestimmen. Dabei soll lediglich die Position im Raum und nicht seine Orientierung betrachtet werden. Der Zustandsraum besteht damit aus X, Y, und Z-Koordinaten. Für das Dynamikmodell könnten hier die Keplerschen Gesetze zur Bahnberechnung verwendet werden. Allerdings ist es dafür nötig, die Geschwindigkeit des Objektes zu kennen. Dazu wird der Zustandsraum um die Geschwindigkeiten in X, Y und Z-Richtung erweitert. Nun ist es bei einem gegebenen Zustand möglich, einen Folgezustand nach einer verstrichenen Zeit zu errechnen. Diese Prognose wird allerdings mit der Zeit immer ungenauer, denn in der Realität gibt es immer Störgrößen, die sich nicht vorhersagen lassen. Häufig jedoch lassen

sich Aussagen über die Art und Stärke der Störung machen. Dieses Wissen kann in Form von einer Wahrscheinlichkeitsverteilung, die um die Prognose verteilt liegt, verwendet werden. Bei dem Satelliten wäre als Störung der Einfluss von Sonnenwind denkbar, der ihn von der Sonne weg beschleunigt. Ist bekannt, wie stark der Einfluss werden kann, könnte man ihn als statistische Größe in die Prognose einfließen lassen.

### **Messmodell**

Das Messmodell wird benötigt, um entscheiden zu können, wie plausibel eine Messung bei gegebenem Zustand (Beispiel: die Position) ist. Ein Sensor, über den das System verfügt, liefert einen Messwert. Mit dem Messmodell kann zu einem beliebigen Zustand eine Aussage darüber gemacht werden, wie wahrscheinlich es wäre, diesen Messwert zu messen. Im Beispiel des Satelliten könnte der Abstand zu einer Bodenstation gemessen werden. Im Messmodell würde dann aus einem gegebenen Zustand, also Position und Geschwindigkeit, zusammen mit weiteren Informationen, wie Position der Bodenstation auf der Erde sowie Datum und Uhrzeit der Messung errechnet werden wie groß der Abstand sein müsste. Je stärker dieser erwartete Abstand von dem gemessenen abweicht, um so unwahrscheinlicher ist die Messung bei diesem Zustand (Position und Geschwindigkeit). Zusätzlich ist jeder Messwert mit einer Ungenauigkeit behaftet, die vom Messprinzip und Sensortyp abhängt. Aber auch diese lässt sich statistisch angeben und auf den Messwert aufschlagen, bevor er ins Messmodell gegeben wird. Auf diese Weise lassen sich Zustände im Zustandsraum hervorheben, für die eine gegebene Messung wahrscheinlich sind.

### **Angewendet auf den Filter**

Wenn der Zustandsraum alle möglichen Zustände eines Systems beschreibt, so sind die Partikel des Partikelfilters eine Untermenge davon, die in ihrer räumlichen Häufung den tatsächlichen Zustand des Systems beschreiben. Während des Betriebs gibt es zwei Ereignisse auf die der Filter reagiert:

Das **Dynamik-Update** berechnet auf Grundlage des Dynamikmodells eine neue Prognose. Konkret wird im Partikelfilter dafür zu jedem Partikel eine eigene Prognose gestellt. Dabei wird eventuelles Systemrauschen durch eine Ziehung pro Partikel aus dessen Wahrscheinlichkeitsverteilung (häufig Gaußverteilung) abgebildet. Die Prognosen aller Partikel bilden dann den neuen Systemzustand.

Der **Mess-Update** Aufruf verarbeitet eine Messung mit Hilfe des Messmodells. Dabei wird für jedes Partikel, und damit den Zustand den es repräsentiert, geprüft wie wahrscheinlich eine solche Messung wäre. Bei einer hohen Wahrscheinlichkeit, wird der Gewichtungswert im Partikel größer. Bei geringer Wahrscheinlichkeit für eine solche Messung sinkt der Gewichtungswert. Nun repräsentieren diese Gewichte der Partikel den neuen Systemzustand.

Ein **Resampling** überführt die Information in den Partikelgewichten wieder in die Partikelhäufung. Es wird normalerweise nach jedem Mess-Update vorgenommen. Dies geschieht durch Ziehen von Partikeln aus der alten Partikelmenge mit einer Wahrscheinlichkeit die proportional zum Gewicht eines Partikels ist. Somit werden Partikel, die ein hohes Gewicht hatten, häufiger gezogen als jene, die nur ein geringes Gewicht hatten. Damit "überleben" das Resampling die Partikel, deren Zustand von einer vorgenommenen Messung bestätigt wird. Nach der Neuziehung wird das Gesamtpartikelgewicht wieder auf 1 normalisiert und alle Partikel erhalten das selbe Gewicht. In [Thrun et al., 2006, S. 108] wird ein Problem beim Resampling beschrieben, welches bei unabhängigen Ziehungen auftritt. Es wird *variance reduction* genannt und führt dazu, dass Partikel mit geringem Gewicht durch Zufall unterproportional oft oder gar nicht gezogen werden. Dies bedeutet einen Informationsverlust, der sich mit wiederholtem Resampling im Extremfall auf nur einen einzigen Zustand reduziert. Um dem entgegenzuwirken, sollte das Resampling nur durchgeführt werden, wenn sich die Gewichte in den Partikeln verändert haben - beispielsweise nach einer Messung. Ist aber davon auszugehen, dass sich am Zustand nichts ändern kann (z.B. weil der Roboter stillsteht), sollten weder Messungen ausgewertet, noch ein Resampling durchführen werden. Zudem sollte systematisches Ziehen anstelle von unabhängigen Ziehungen eingesetzt werden. Hierbei wird ein Partikel zufällig ausgewählt und die übrigen systematisch anhand ihrer Gewichtung ermittelt.

## 2.4 Bildverarbeitung

Eine wichtige Grundlage für das Verständnis der Funktion des entwickelten Verfahrens ist das Prinzip mit der Bilder in der am Roboter montierten Kamera aufgenommen werden. Diese werden als Messung dienen und daher soll an dieser Stelle kurz darauf eingegangen werden, wie sich eine Kamera formal beschreiben lässt.

Das Lochkamera-Modell wird häufig zur Veranschaulichung verwendet. Es vereinfacht viele physikalische Effekte, ist aber eine gute Näherung für die meisten Anwendungen. Für eine detaillierte Beschreibung wären [Jähne, 2005, S. 203] oder

[Tönnies, 2005, S. 47] zu empfehlen. Es folgt eine Kurzbeschreibung der wichtigsten Begriffe:

Die Kamera projiziert im Punkte aus dem Raum (3D) auf die Bildebene (2D). Um nun bei gegebenen Koordinaten eines 3D-Punktes in Weltkoordinaten den passenden Punkt auf der Bildebene berechnen zu können, ist die Kenntnis verschiedener Parameter erforderlich. Dabei trennt man in extrinsische und intrinsische Parameter. Unter den extrinsischen Kameraparametern versteht man die Pose der Kamera in Weltkoordinaten, also wo sich sie befindet und wie sie ausgerichtet ist. Dies wird in einer Transformationsmatrix ausgedrückt, mit der sich Punkte zwischen dem Kamera- und Weltkoordinatensystem transformieren lassen.

Die intrinsischen Parameter sind nötig, um 3D-Punkte (in Kamerakoordinaten) auf die Bildebene und in Pixelkoordinaten zu projizieren. Sie beinhalten neben der Brennweite der Kamera, auch die Koordinaten, wo die optische Achse auf den Bildsensor trifft. Mit Hilfe eines Skalierungsfaktors können die projizierten Punkte auf dem Bildsensor in Pixelkoordinaten umgerechnet werden.

Bei realen Kameras muss in der Regel eine Kalibrierung durchgeführt werden um diese Parameter zu bestimmen. Dabei können die intrinsischen Parameter gespeichert und wieder verwendet werden, wenn sich die Brennweite nicht ändert (kein optischer Zoom). Die extrinsischen Parameter müssen neu bestimmt werden, sobald sich die Kamera bewegt. Alternativ muss die Bewegung bekannt sein, um sie in die Transformationsmatrix einfließen zu lassen.

## 3 Lokalisierung mittels Bildverarbeitung

In diesem Kapitel wird das in dieser Arbeit entwickelte Verfahren beschrieben, mit dem die Lokalisierung erfolgt. Dabei wird erklärt, wie das zu erkennende Bitmuster aufgebaut ist, wie der eingesetzte Partikelfilter ausgelegt wurde und wie der Filter die Bilder beurteilt. Im letzten Abschnitt wird auf verschiedene Parameter eingegangen, die Einstellmöglichkeiten des Filters erlauben.

### 3.1 Bitmuster

Die drei Bitmuster in den obersten Zeilen der Lichtwände sind 64 Bit lang, da eine Lichtwand aus 8 Segmenten mit je 8 Bit aufgebaut ist. Jedes Segment ist 1 m lang. Damit ist ein Bit 125 x 125 mm groß. Als Muster wurde eine Zeichenfolge in Strichcode verwendet. Als Codierung wurde ein Verfahren gewählt, welches Code 93<sup>1</sup> genannt wird und von der Firma Intermec entwickelt wurde. Er codiert 48 verschiedene Zeichen in 9 Bit langen Blöcken in denen höchstens 4 gleiche Bits aufeinander folgen können. Dabei sind mindestens 3 Bit immer **true** (1) und 3 immer **false** (0). Code 93 wurde gewählt, weil es sicherstellen konnte, dass es auch in beliebigen Ausschnitten der Muster genug Unterschiede zwischen den Lichtwänden gab. Auf Abbildung 3.1 sind die drei verwendeten Codestreifen dargestellt. Rechts davon wurden die Zeichen für den codierten Abschnitt angegeben. Es sind 9 Bit lange Blöcke. Es gibt 7 solcher Blöcke die 63 Bits füllen, das letzte Bit ist bei zwei Codestreifen schwarz und




Abbildung 3.1: Muster

<sup>1</sup>Quelle: <http://www.suchymips.de/de/code-93.htm>

bei einem weiß gewählt worden. Eine vollständige Tabelle der Codierung befindet sich im Anhang auf Seite VI.

## 3.2 Partikelfilter

Für die Lokalisierung wird ein Partikelfilter verwendet. In diesem Abschnitt wird erläutert, wie dieser entworfen und der Zustandsraum gewählt wurde. Ferner wird beschrieben, wie viele Partikel verwendet werden und wie das Dynamikmodell die Odometrie der Antriebe verwendet um die Pose des Roboters zu schätzen. Die Beschreibung des Messmodells umfasst, wie die Bilder der Kamera verwendet werden.

### 3.2.1 Zustandsraum

Der Zustandsraum der Partikel setzt sich aus der Position und der Pose des Roboters zusammen. Da er sich ausschließlich auf einer ebenen Bühne befindet, führt dies zur Reduktion der Freiheitsgrade von sechs auf drei:

**x und y** sind die Koordinaten des Roboters auf der Bühne. Der Ursprung ist dabei in der Mitte der Bühne. Die x-Achse zeigt von der Bühnenseite ohne Lichtwand weg und auf die mittlere Lichtwand zu. Die z-Achse zeigt nach Oben und bildet zusammen mit der x- und y-Achse ein Rechtssystem.

**Der Winkel  $\psi$**  repräsentiert die Orientierung des Roboters relativ zur Bühne. Er ist zwischen Roboter x-Achse und Welt x-Achse (Bühne) bei Drehung um die z-Achse.

Bei der Anzahl der Partikel gilt grundsätzlich, dass so viele wie möglich verwendet werden sollten um den Filter möglichst robust zu machen, da so eine größere Chance besteht, den wahren Zustand mit Partikeln abgedeckt zu haben. Beschränkt wird dies normalerweise von der zur Verfügung stehenden Rechenkapazität und der Zeit, in der alle Partikel im Mess-Update verarbeitet werden sollen. Bei einer Anwendung die echtzeitfähig sein soll, ist die Zeit, die ein Mess-Update benötigt ein wichtiges Kriterium. Unter diesem Aspekt wäre die Anzahl so groß wie nötig, aber so klein wie möglich zu wählen. Für die Simulation sollen 2500 Partikel eingesetzt werden. Dies sind verhältnismäßig wenige. Die Partikelanzahlen in der Literatur ([Thrun et al., 2006], [Hertzberg et al., 2012]) sind meist im Bereich von mehreren Tausend Partikeln. In der Simulation scheinen aber 2500 Partikel zunächst ausrei-



chend zu sein um die Lokalisation zu ermöglichen. Beim Einsatz auf einem Roboter wäre sie der Hardware angemessen zu wählen.

### 3.2.2 Dynamikmodell

Das Dynamikmodell für den Roboter basiert auf der Odometrie. Als Eingabe bekommt das Dynamik-Update die Encoder-Messwerte des linken und rechten Rades. Es sind absolute Werte, aus denen die Differenzen  $\Delta I_{r/l}$  zum letzten Update gebildet werden. Sie werden verwendet, um daraus eine Vorwärtsfahrt  $\Delta s$  und einen Drehwinkel  $\Delta\psi$  zu berechnen:

$$\Delta s = \frac{\Delta I_r + \Delta I_l}{2} \cdot \underbrace{\frac{2\pi r}{g \cdot \gamma}}_E \quad (3.1)$$

$$\Delta\psi = \frac{\Delta I_r - \Delta I_l}{2} \cdot \frac{2 \cdot E}{D} \quad (3.2)$$

mit Radabstand  $D$ , Getriebeübersetzung  $g$ , Radradius  $r$  und Geberauflösung  $\gamma$

Jedes Partikel berechnet daraus seinen neuen Zustand:

$$x_t = x_{t-1} + \cos(\psi_{t-1} + \frac{\Delta\psi}{2}) \cdot \Delta s \quad (3.3)$$

$$y_t = y_{t-1} + \sin(\psi_{t-1} + \frac{\Delta\psi}{2}) \cdot \Delta s \quad (3.4)$$

$$\psi_t = \psi_{t-1} + \Delta\psi \quad (3.5)$$

Dabei wird rechnerisch erst eine Drehung um  $\frac{\Delta\psi}{2}$  vollzogen, gefolgt von der Geradeausfahrt um  $\Delta s$  mit einer abschließenden Drehung um  $\frac{\Delta\psi}{2}$ . Damit der Partikelfilter funktioniert, muss er die Messunsicherheiten der Eingangswerte berücksichtigen. Dazu wird vor der Zustandsberechnung, zu  $\Delta s$  und  $\Delta\psi$  ein gaußsches Rauschen addiert. Es ist proportional zu deren Betrag:

$$\Delta s_{err} = \Delta s \cdot \sigma_s \cdot \text{RandomGaussian}() \quad (3.6)$$

$$\Delta\psi_{err} = \Delta\psi \cdot \sigma_\psi \cdot \text{RandomGaussian}() \quad (3.7)$$

$\sigma_s$  und  $\sigma_\psi$  sind dabei ein Maß dafür, wie breit die Streuung der Normalverteilung ist. Sie sind Parameter die auf den Anwendungsfall, nach Stärke des erwarteten Rauschens, eingestellt werden müssen. Dabei soll die Streuung der Partikel im Zustandsraum mindestens genau so groß sein, wie die Streuung um den wahren Wert, verursacht durch Messunsicherheit der Sensoren. Wird das  $\sigma$  zu klein gewählt, so kann es passieren, dass die Verteilung der Partikel den wahren Zustand nicht mehr

enthält. Somit gäbe es bei einer Messung kein Partikel mehr, dessen Zustand diese als wahrscheinlich erscheinen ließe. Damit folgten die Partikel im Zustandsraum einer falschen Schätzung und die Messungen wären wertlos. Der Partikelfilter hätte die Position verloren.

Setzt man das  $\sigma$  größer an, so divergieren die Partikel mit jedem Dynamik-Update stärker. Der wahre Wert wird so mit hoher Wahrscheinlichkeit von Partikeln abgedeckt, so dass bei einer Messung diese einen guten Score bekommen. Durch ein anschließendes Resampling konzentrieren sich die Partikel wieder um den wahren Wert. Allerdings ist bei zu großem  $\sigma$  die Aussagekraft der Partikelverteilung sehr ungenau und es sind viele Partikel nötig, um die notwendige Dichte im Zustandsraum zu gewährleisten. Dabei spielt es eine entscheidende Rolle, wie häufig Messungen erfolgen, weil sich der Filter zwischen den Messungen auf das Dynamikmodell verlassen muss. Bei großem  $\sigma$  ist die Schätzung nach wenigen Schritten bereits mit einer großen Unsicherheit verbunden.

### 3.2.3 Messmodell

Als Messungen werden die Bilder einer Kamera auf dem Roboter verwendet. Das Messmodell dahinter beruht auf dem Wissen um die Position der erwähnten Muster in der Umgebung. Dies kann als Karte der Umgebung verstanden werden, anhand derer sich der Roboter orientieren muss. Auf jeder der drei Lichtwände gibt es jeweils ein eindeutiges Muster. Sie werden in der obersten Zeile der Lichtwand angezeigt, um möglichst selten verdeckt zu werden. Bei dem Messmodell gilt es nun zu prüfen, ob ein Bild zu einer bestimmten Pose passt. Ein Ansatz wäre, in dem Bild nach den bekannten Mustern zu suchen, und sobald diese gefunden sind zu versuchen diese einer Pose zuzuordnen. Eine solche Mustersuche in einem Bild ist immer in verschiedene Schritte aufgeteilt, die aufeinander aufbauen. Beispielsweise Binarisierung über einen Schwellwert, Regionenbildung mit Charakterisierung und anschließender Auswertung ausgewählter Regionen. Alternativ Kantenerkennung, Hough-Transformation und finden von parallelen kurzen Linien. Problematisch an solchen schrittweisen Verfahren ist, wenn in einem ersten Schritt z.B. ein Schwellwert falsch gewählt wurde, oder nur sehr schwache Kanten vorhanden sind, alle folgenden Schritte scheitern, weil ihre Vorbedingungen nicht ausreichend erfüllt werden. Aus diesem Grund wurde ein anderer Ansatz verfolgt, bei dem nicht das Bild und die Informationen darin als Ausgangspunkt verwendet werden, sondern die Pose der Partikel und die Position der Muster im Raum. Dazu wird aus den Koordinaten des Roboters auf der Bühne und dessen Ausrichtung die Pose der Kamera berechnet und

anschließend die Position des Musters aus dem Raum in Pixelkoordinaten projiziert werden. Damit könnte für jede beliebige Pose des Roboters ermittelt werden, wo im Bild das Muster zu sehen sein müsste und diese Bereiche mit dem erwarteten Muster verglichen werden. Je besser der Bereich zu dem Muster passt, desto höher wird der Score für die Partikelbewertung. Wie die gefundenen Pixel im Bild mit dem erwarteten Muster verglichen werden, wird in Abschnitt 3.3 näher beschrieben. Um die Position des Musters im Bild aus der Roboter Position zu berechnen sind mehrere Koordinatentransformationen und eine Projektion nötig. Die Musterposition liegt als Punktmenge  $M_W$  der Pixelmittelpunkte in Weltkoordinaten vor. Um sie mit der Kameragleichung in das Bild zu projizieren, müssen sie in die Kamerakoordinaten transformiert werden. Dazu sind folgende Schritte nötig:

**Welt zu Roboter** ( $T_R^W$ ) In diese Transformation fließt die Pose des Roboters ein, die in Weltkoordinate vorliegt. Diese Transformation besteht aus Translation in x- und y-Richtung sowie einer Drehung um die z-Achse mit dem Winkel  $\psi$ . Sie muss für jedes Partikel neu erzeugt werden. Da die Pose sich ständig ändert, und unter den Partikeln verschieden ist.

$$T_R^W = \begin{pmatrix} \cos(\psi) & -\sin(\psi) & 0 & 0 \\ \sin(\psi) & \cos(\psi) & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & x \\ 0 & 1 & 0 & y \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (3.8)$$

**Roboter zu Kamera** ( $T_K^R$ ) Diese Transformation entspricht der extrinsischen Kameramatrix, welche die Pose der Kamera relativ zum Roboter ausdrückt. In der Simulation wurde sie in 500 mm Höhe am Roboter angebracht. Sie blickt in Fahrtrichtung und ist 30° nach Oben geneigt. Ist diese Transformation einmal bekannt, so kann sie immer wieder verwendet werden. In dieser Arbeit ist sie aus der Simulation bekannt. Werden Bilder einer realen Kamera verwendet, muss die Pose der Kamera am Roboter mit Hilfe einer Kalibrierung ermittelt werden. Um dieses Verfahren untersuchen zu können, wird auf die Problematik der Kamerakalibrierung in dieser Arbeit nicht weiter eingegangen.

Durch Multiplikation der Transformationmatrizen

$$M_K = T_K^R \cdot T_R^W \cdot M_W \quad (3.9)$$

erhält man die Koordinaten der Bitmuster im Kamerasystem  $M_K$ . Diese können nun mit einer perspektivischen Projektion

$$P \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{x}{z} \\ \frac{y}{z} \\ 1 \end{pmatrix} \quad (3.10)$$

und der intrinsischen Kameramatrix

$$K_i = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \quad (3.11)$$

in eine Punktmenge in Pixelkoordinaten  $M_P$  projiziert werden

$$M_P = K_i \cdot M_K \quad (3.12)$$

### 3.2.4 Initialisierung

Zu Beginn der Lokalisation muss den Partikeln eine Anfangsposition zugewiesen werden. Es könnte entweder eine feste Startposition des Roboters festgelegt werden, oder es muss eine Globale Lokalisation durchgeführt werden wie in Abschnitt 2.3 beschrieben. Die übliche Vorgehensweise um den korrekten Anfangszustand zu erhalten, ist die erste Messung zu verwenden und den gesamten Zustandsraum nach korrespondierenden Zuständen zu durchsuchen. Da ein Durchsuchen des gesamten Raumes sehr lange dauern würde, wurde dieser eingegrenzt und damit eine Forderung an die Anfangs Pose des Roboters gestellt. Für die anfängliche Globale Lokalisierung muss der Roboter das Bit-Muster der mittleren Lichtwand sehen können. Es wird gefordert, dass dieser in Richtung x-Achse ausgerichtet ist mit einer Toleranz von  $\mp 20^\circ$  der Blickrichtung. An die genaue Position auf der Bühne wird keine weitere Anforderung gestellt, solange das Bit-Muster sich im Bild befindet, und der Blickwinkel in der Toleranz ist. In einer realen Anwendung würde der Roboter etwa mittig auf die Bühne gestellt und in Richtung der mittleren Lichtwand gedreht werden. Nach einigen Minuten wäre die Globale Lokalisation abgeschlossen und der Roboter kann seinen programmierten Weg zurücklegen. Da die Lokalisation nur einmal zu Beginn stattfinden muss, sollte dieses Verfahren zu der von BBM beschriebenen Anwendung passen.

### 3.2.5 Schätzung aus Partikeln berechnen

Der Algorithmus soll die Position des Roboters auf der Bühne, sowie dessen Orientierung angeben können. Weil dem Partikel-Filter diese Information nur in der Partikelverteilung im Zustandsraum bekannt ist, muss eine geschätzte mittlere Position berechnet werden. Um einschätzen zu können, wie verlässlich diese Positionsangabe ist, wird zusätzlich noch die Varianz berechnet. Für die Position, als zweidimensionale Größe, wird sie als Ellipse um die Position ausgegeben und besteht aus großer Halbachse, kleiner Halbachse und Winkel zur x-Achse des Bühnenkoordinatensystems. Die Ellipse drückt den Vertrauensbereich aus, der  $3\sigma$  einer Normalverteilung entspricht. Für den Winkel wird neben dem Mittelwert die Standardabweichung berechnet. Damit steht die Mittlere Pose des Roboters über alle Partikel samt Standardabweichung zur Verfügung.

## 3.3 Musterbewertung

Ziel der Musterbewertung ist es, bei einer bekannten Region im Bild zu bewerten, wie gut sie zu einem gegebenen Muster passt. Bei der Bewertung wird zu jedem Bit des Musters geprüft, ob an dessen Position ein schwarzer oder ein weißer Wert vorliegt. Dabei soll ein Score berechnet werden der zwischen 0 und 1 liegt. Wobei 0 keinerlei und 1 volle Übereinstimmung signalisiert. Es ist gewollt, dass hier keine harte Entscheidung getroffen wird. Denn damit gehen Informationen verloren, die zur Lokalisierung beitragen. Wenn beispielsweise ein Teil des Musters verdeckt wurde, so wäre immer noch ein mittlerer Score möglich. Bei einer harten Entscheidung würden Partikel zu denen das Bild normalerweise passt genau so schlecht bewertet wie alle anderen.

### 3.3.1 Spezialfall: Projektion ergibt keine Bildpunkte

Für die Musterbewertung stehen die Bildpositionen jedes Bits der drei Bitmuster aus der Projektion zur Verfügung. Dabei entspricht sie stets dem Mittelpunkt der  $125 \times 125 \text{ mm}$  großen Bits der Lichtwände. Der erste Schritt ist eine Überprüfung, ob die Pixelkoordinaten der Muster-Bits tatsächlich in dem Bild liegen, da die Projektion nicht auf einen Bildausschnitt beschränkt ist. Aus der Menge der Bildpunkte die ein Muster-Bit repräsentieren  $M_P$  können so alle aussortiert werden, die sich nicht in dem betrachteten Bildausschnitt befinden. Ein Spezialfall wäre nun, dass sich kein

Muster-Bit als Punkt im Bild befindet. In diesem Fall wird ein fester Score gegeben, der nicht 0 sein darf. Null wäre für den Partikelfilter problematisch, da dieser das Gewicht des Partikels mit dem Score multipliziert um es zu bewerten. Es gibt hier zwei Fälle die zu unterscheiden sind:

**Wahrer Zustand lässt kein Muster zu:** Der Roboter und damit die Kamera stehen so zu den Lichtwänden, dass sich kein Bit-Muster im Bild befindet. Damit gibt es, bei Partikeln die dieser Ausrichtung entsprechen, keine Punkte im Bild die sich auswerten lassen. Würde man einen Score von 0 geben, so würde der richtige Zustand, wegen der Multiplikation und anschließendem Resampling, gelöscht werden. Dies ist nicht erwünscht. Eine mögliche Lösung wäre in diesem Fall das Partikel mit einem mittlerem Score zu bewerten um den richtigen Zustand zu schützen. Ein zu hoher Score wäre jedoch im Folgenden Fall ungünstig.

**Falscher Zustand lässt kein Muster zu:** Ein Partikel, dessen Zustand stark von der wahren Pose abweicht, führt zu keinen Bildpunkten für das Bit-Muster. Im Bild befindet sich aber ein Bit-Muster. Deshalb müsste es andere Partikel geben, deren Zustände zum Bild passen und nicht automatisch einen festen Score bekommen. Würde nun, wie im ersten Fall vorgeschlagen, ein mittlerer Score gegeben, würde dieses Partikel überbewertet werden. Im Vergleich zu Partikeln dessen Zustand ein Bit-Muster an falscher Stelle vorhersagt, wäre dieser Fall erheblich besser bewertet. Auch wenn ein kleiner Wert gewählt wird, könnte eine ungünstige Vorhersage bei einem anderen Partikel einen schlechteren Score ergeben. Angestrebt wäre aber, dass dieser zweite Fall möglichst schlecht bewertet wird.

Aus diesem Grund wird ein Minimalscore von 0,01 festgelegt der in diesen Fällen verwendet wird. Zudem wird auch bei vorhandenem Bildpunkten für Bit-Muster bei dessen Auswertung mindestens dieser Minimalscore gegeben. Dadurch werden beim ersten Fall, bei dem kein richtiges Bit-Muster zum Auswerten im Bild ist, alle Partikel gleich bewertet. Da es kein Partikel gibt, welches einen hohen Score zugeordnet bekommt. Es muss nur sichergestellt werden, dass die Auswertung beliebiger Bildpunkte als Bit-Muster den Minimalscore möglichst nicht übertrifft. Um dies zu prüfen, wurde zu einem Testbild (siehe Abbildung 3.2) für 1,8 Millionen Posen, die gleichmäßig über den Zustandsraum verteilt waren, der Score berechnet. Nur 136 davon lagen über dem Minimalscore von 0,01. Wie in Bild 3.2 unten zu sehen, gibt es keine starke Häufung der Scores die über dem Minimum liegen, zudem ist kein Score über 0,25. Eine so geringe Anzahl von Überschreitungen des Minimalscores

wird als akzeptabel angesehen.

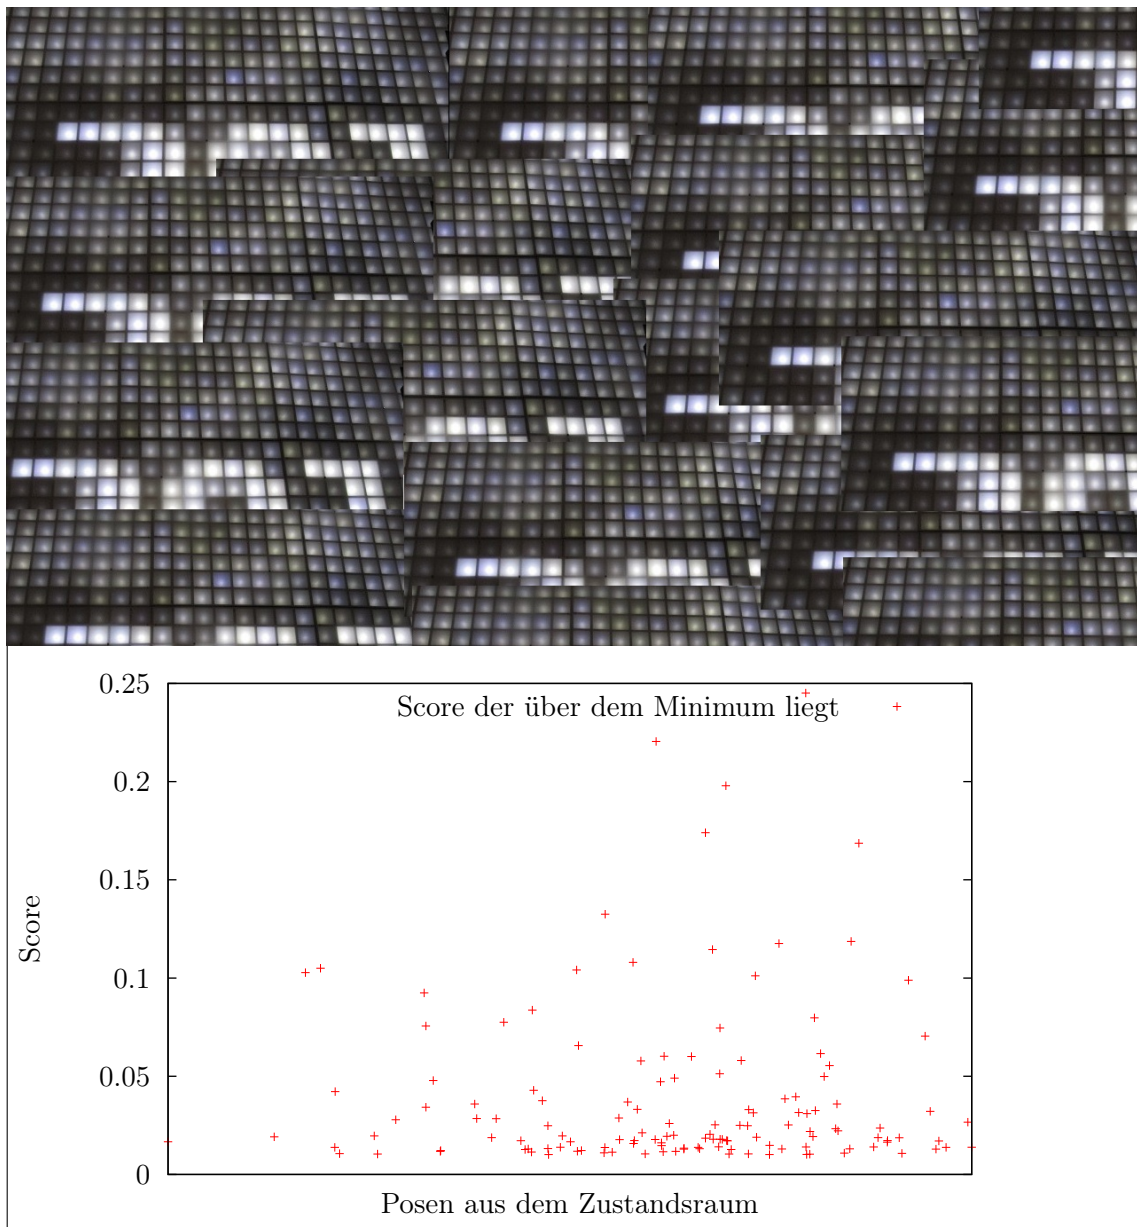


Abbildung 3.2: 1,8 Millionen Posen wurden mit dem Bild oben Bewertet. Nur 136 davon liegen über dem Minimalscore. Sie sind hier abgebildet.

Werden alle Partikel mit dem selben Score bewertet, erhalten sie damit alle das gleiche Gewicht. Dies führt während des Resampling dazu, dass die Partikelverteilung erhalten bleibt. Für den zweiten Fall sollte es andere Partikel geben, deren Zustände im Bild ein Bit-Muster treffen und die damit einen höheren Score bekommen. Wäre dies nicht der Fall, so wäre die Lokalisation fehlgeschlagen. Dadurch, dass der Minimalscore die geringste Bewertung ist die ein Partikel bekommen kann, gibt es das Problem einer Überbewertung nicht mehr.

### 3.3.2 Mindestanzahl auswertbarer Bildpunkte

Vorraussetzung für eine adäquate Auswertung der Bit-Muster ist eine Mindestanzahl an Punkten im Bild. Für die Mindestanzahl auswertbarer Punkte wurde 18 gewählt. Dies soll verhindern, dass wenige Punkte auf Bildbereichen liegen, die zufällig gut zum gesuchten Bit-Muster passen. Je größer die Anzahl der Ausgewerteten Punkte ist, desto unwahrscheinlicher ist dies. Ferner ist mit 18 Punkten sichergestellt, dass keine Teile des Bit-Musters von einem Streifen auf einem anderen gefunden werden. Da die Codebausteine einzeln immer 9 Bits lang sind und im Gesamtmuster einzigartig. Wird diese Mindestanzahl nicht erfüllt, ergibt sich ebenfalls der Minimalscore.

### 3.3.3 Bestimmung mittlerer Weiß- und Schwarzwerte

Um einen Vergleich anstellen zu können, ob ein Bit im Bild schwarz oder weiß ist, sollen keine absoluten Weiß- und Schwarzwerte verwendet werden. Stattdessen wird über alle weißen Bits im Bild ein mittlerer Weißwert  $\hat{h}_w$  errechnet:

$$\hat{h}_w = \frac{1}{n} \sum_{i=1}^n h_w(i) \quad (3.13)$$

Für den Schwarzwert  $\hat{h}_s$  wird genauso verfahren. Aus diesen beiden Größen wird außerdem die Differenz  $\kappa$  gebildet:

$$\kappa = \hat{h}_w - \hat{h}_s \quad (3.14)$$

An ihr lässt sich prüfen, ob sie negativ oder Null ist. Es würde darauf schließen lassen, dass ein falsches (oder kein) Muster vorliegt. Trifft dies zu, so wird der Minimalscore vergeben.

### 3.3.4 Bewertungskriterium

Für den Score  $P$  der übrigen Bit-Musterpunkte wird ein quadratischer Abstand in der Helligkeit  $\Delta h_i$  vom jeweiligen Referenzwert  $\hat{h}$  verwendet:

$$\Delta h_i = (h_i - \hat{h}_{w/s})^2 \quad (3.15)$$

abhängig davon, ob im Muster ein schwarzes oder ein weißes Bit erwartet wird. Je größer dieser Abstand wird, umso schlechter passt dieses Bit aus dem Bild in das Bit-Muster. Diesen Abstand direkt in den Score einfließen zu lassen, ist bei sehr kontrastarmen Bildern problematisch. Da der Vergleichswert für Schwarz und



Weiß aus dem Bild berechnet wird, wären sie bei einfarbigen Flächen identisch. Es bestünde die Möglichkeit, dass eine solche Fläche einen hohen Score bekommt, ohne das Bit-Muster auszuwerten. Dies wäre bei ungünstigem Bildrauschen möglich, bei dem zufällig schwarze Bits dunkler und weiße Bits heller sind. Durch den geringen Kontrast sind die Abstände nur sehr klein, dies würde zu einem hohen Score führen. Da dieser Abstand bei sinkendem Kontrast immer schwächer wird, fließt zusätzlich noch  $\kappa$  mit in die Berechnung für den Score eines Bits  $p_i$  ein:

$$p_i = \Delta h_i \cdot \frac{\kappa_{min}^2}{\kappa^2} \quad (3.16)$$

mit  $\kappa_{min}$  als Parameter lässt sich einstellen bis zu welcher Größe sich  $\kappa$  negativ auf den Score auswirkt. Und ab wann es den Score positiv beeinflusst. Ein Wert von 20 für  $\kappa_{min}$  ist ausreichend, um den Gesamtscore des Musters bei geringem Kontrast deutlich zu senken und unterstützt bei gutem Kontrast den Score. Nach diesem Verfahren wird für jedes Bit ein solcher Score berechnet und der Mittelwert daraus gebildet:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n (h_i - \hat{h}_{w/s})^2 \cdot \frac{\kappa_{min}^2}{\kappa^2} \quad (3.17)$$

Die Bildung des Mittelwertes ist nötig, damit der Score unabhängig von der Anzahl der sichtbaren Bits bleibt. Eine einfache Summe würde dazu führen, dass viele Bits einen schlechteren Score bekommen als wenige. Der letzte Schritte der Bewertung ist eine Exponentialfunktion mit negativem Exponenten:

$$P = e^{-\frac{\hat{p}}{2}} \quad (3.18)$$

Sie führt bei sehr kleinem  $\hat{p}$  zu einem Score nahe 1, während bei großem  $\hat{p}$  der Score gegen 0 geht. Dieses Verhalten ist nötig um den Score mit dem Gewicht der Partikel multiplizieren zu können. Sie stellt sicher, dass der Score  $P$  immer im Intervall  $[0..1]$  bleibt

### 3.4 Parameter einstellen

An dieser Stelle soll beschrieben werden, mit welchen Größen das Verhalten von Filter und Bildbewertung beeinflusst werden können. Für den Filter lassen sich folgende Variablen setzen:

**Anzahl der Partikel** ( $N_p = 2500$ ) Wie in Abschnitt 3.2.1 beschrieben werden 2500 Partikel eingesetzt. Je nach Anwendung muss ihre Anzahl angepasst werden. Sie ist dabei besonders von den Rechenkapazitäten abhängig die zur Verfügung stehen, sowie den zeitlichen Anforderungen.

**Raddurchmesser** ( $R = 80mm$ ) Der Filter nutzt diesen Parameter um aus Radumdrehungen eine zurückgelegte Strecke zu berechnen. Dies ist für die Berechnungen im Dynamik-Update relevant.

**Getriebeübersetzung** ( $g = 14,5$ ) Die Getriebeübersetzung wird vom Filter verwendet, um von Umdrehungen des Encoders in Radumdrehungen umzurechnen. Dabei ist ein Verhältnis  $g : 1$  bzw. Encoder:Rad gemeint.

**Auflösung Drehimpulsgeber** ( $\gamma = 2000 \frac{1}{U}$ )

**Impulse pro Meter** ( $I_m = 57693.67$ ) Diese Größe kombiniert mehrere Maße und Parameter des Antriebs und des Encoders. Mit ihr lässt sich aus einer Anzahl von Impulsen des Encoders die gefahrene Strecke berechnen. Darin enthalten sind:

$$I_m = \frac{g \cdot \gamma}{2\pi R} = \frac{14,5 \cdot 2000}{2\pi \cdot 0,08m} = 57693,67 \frac{1}{m} \quad (3.19)$$

**Abstand zwischen den Rädern** ( $D_R = 700mm$ ) Dieser Parameter wird verwendet, um bei Drehungen den zurück gelegten Weg der Räder berechnen zu können. Im Filter wird aus Differenzen des linken und rechten Encoders damit ein Drehwinkel bestimmt.

**Unsicherheits Koeffizient Strecke** ( $\sigma_s = 0.2$ ) Diese Größe steuert wie groß das Rauschen ist welches auf die Bewegung eines Partikels wirkt. Dabei ist  $\sigma_s$  eine Prozentgröße. Sie wird mit dem zu verrauschenden Wert und der Ziehung einer Gaußschen Normalverteilung multipliziert.

**Unsicherheits Koeffizient Drehung** ( $\sigma_\psi = 0.2$ ) Dieser Koeffizient ist ebenfalls eine prozentuale Größe wie  $\sigma_s$ . Er bezieht sich jedoch nur auf Drehungen. Er wird genau so verrechnet wie der Koeffizient für eine Strecke.

Für die Musterbewertung sind folgende Parameter relevant:

**Mindestanzahl an sichtbaren Bits** ( $B_{min} = 18$ ) Bei der Bildauswertung werden Partikel automatisch mit dem Mindestscore bewertet, wenn weniger als  $B_{min}$  Positionen für Bit-Muster berechnet wurden. Dies dient vor allem dem Schutz vor fehlerhaften hohen Scores durch zufälliges Übereinstimmen weniger Pixel im Bild.

**Kontrast Grenzwert** ( $K_T = 20$ ) Wenn der mittlere Kontrast über alle Pixel in den Bit-Musterpositionen kleiner wird als  $K_T$ , wird der Score abgewertet. Ist er größer, wird er verbessert.

**Größe Pixelgrid** ( $U_{Pix} = 1$ ) An den Positionen an denen ein Bit-Muster vermutet wird, können unterschiedlich viele Pixel ausgewertet werden. Mit  $U_{Pixel} = 0$  würde nur ein Pixel an der Position betrachtet werden. Der Wert gibt an wie viele benachbarte Pixel in jede Richtung mit in die Berechnungen einbezogen werden sollen. Ein Wert von 3 würde ein 7 x 7 Raster mit 49 Pixeln bedeuten.



## 4 Die Simulationssoftware

Die Simulationssoftware und der Lokalisationsalgorithmus die im Rahmen dieser Arbeit entwickelt wurden, sind in der Programmiersprache C++ geschrieben. Als Entwicklungsumgebung wurde Eclipse mit den *C/C++ Development Tools* (CDT) auf einem Linux<sup>1</sup> Betriebssystem verwendet.

Grundlage der Simulation ist das 3D Grafiktoolkit OSG<sup>2</sup>. Mit dieser Bibliothek lässt sich eine 3D Szene in Form eines Graphen aufbauen und mit einem Viewer darstellen. Um den Ablauf kontrollieren zu können, lässt sich die Render-Schleife manuell aufrufen um jeden Frame einzeln berechnen zu lassen. Dies wurde als Simulationsschritt gewählt in dem alle nötigen Berechnungen durchgeführt werden können.

### 4.1 Koordinatensysteme




Abbildung 4.1: Koordinatensysteme in der Simulation

<sup>1</sup>Ubuntu 12.04 LTS

<sup>2</sup><http://www.openscenegraph.org/>

OpenGL und OpenCV definieren die Koordinatensysteme für eine Kamera sehr unterschiedlich. Um die Pose der Kamera aus der Simulation (OpenGL Koordinatensystem) in die extrinsischen Kamera Parameter zu transformieren, wie OpenCV sie verwendet, muss bekannt sein wie diese beiden Systeme zum Weltkoordinatensystem in der Simulation orientiert sind. In Abbildung 4.1 sind alle drei Koordinatensysteme eingezeichnet.

In **OpenCV** ist die Kamera in die positive z-Achse gerichtet und die y-Achse weist auf den unteren Bildrand. Mit der x-Achse Richtung des rechten Bildrandes, ergibt sich ein Rechtssystem. Sein Ursprung liegt in der Bildmitte so, dass die z-Achse durch den Brennpunkt verläuft.

**OpenGL** hat die Blickrichtung der Kamera in negativer z-Achse festgelegt. Die y-Achse weist in Richtung des oberen Bildrandes und mit der x-Achse Richtung des rechten Bildrandes, ergibt sich ebenfalls ein Rechtssystem. Sein Ursprung liegt in der Bildmitte.

Im **Bühnenkoordinatensystem** der Simulation liegen y- und x-Achse in der Ebene der Grundfläche. Die x-Achse weist dabei von der Bühnenseite ohne Lichtwand weg und die z-Achse weist als Normale der Grundfläche nach Oben. Damit ergibt sich ebenfalls ein Rechtssystem, dessen Ursprung die Mitte der Grundfläche ist.

## 4.2 Die Szene

Die Szene in der Simulation ist aus mehreren Komponenten aufgebaut, die im Folgenden näher beschrieben werden. Dabei wird ein Vergleich zu den echten Elementen auf der Bühne gezogen, um zu erläutern wie deren Attribute in der Simulation abgebildet werden können. In Abbildung 4.2 kann man alle Elemente der Szene erkennen.

**Die Grundfläche (1)** der Bühne misst 12 x 12 m. Sie wird als einfach weiße Fläche in der Szene dargestellt. Da die Bildverarbeitung nur auf den Oberen Teil des Bildes beschränkt ist, spielen Farbe und Helligkeit keine Rolle bei der Erkennung des Musters im Bild.

**Die Lichtwände (2,3)** sind zu drei Seiten der Grundfläche aufgestellt. Sie messen 3m in der Höhe und 8m in der Länge. Wie bereits in Abschnitt 3.1 beschrieben soll das Muster in der obersten Zeile der Lichtwände dargestellt werden. Hierzu




Abbildung 4.2: Simulierte Szene

können verschiedene Texturen geladen werden die das Bitmuster enthalten. In der Realität sind die Lichtwände auf der Bühne aus 1 x 1 Meter großen Segmenten zusammen gesetzt, dies wird in der Simulation nicht abgebildet. Es wäre jedoch denkbar, Abstandsänderungen zwischen den Segmenten in den Aufbau der Texturen einfließen zu lassen. Auf jedem Segment sind 8 x 8 Bits unter gebracht. Das macht eine Kantenlänge von 125 mm bei jedem dieser Pixel und 64 Pixel über die ganze Länge einer Wand. Ein solches Segment besteht aus einer milchigen Kunststoffplatte, die auf eine Struktur geschraubt wurde welche für jedes Pixel ein Leuchtmittel vorsieht. Dessen Helligkeit lässt sich einstellen, wäre aber für das Bitmuster auf die Zustände: dunkel(ausgeschaltet) oder hell(ein, mit größter Helligkeit) einzustellen. Die Plexiglasplatte wird also pro Pixel von hinten durchleuchtet. Dies führt dazu, dass die Helligkeitsverteilung in einem beleuchteten Pixel inhomogen ist. In der Mitte ist die größte Helligkeit, während sie radial nach außen abnimmt. Die Ecken der Pixel sind die dunkelsten Stellen. Auf Abbildung 1.2 auf Seite 2 ist dieser Effekt zu erkennen. Er ist stärker, wenn die Leuchtmittel mit niedriger Helligkeit betrieben werden. Bei hoher Helligkeit ist der Effekt noch wahrnehmbar, aber nicht mehr so ausgeprägt. Betrachtet man zwei gleich angesteuerte Pixel ist zu erkennen, dass die Lichtfarbe und Helligkeit leicht von Pixel zu Pixel variiert. All diese Effekte können in der Simulation durch verändern der Texturen abgebildet werden.

**Der Roboter (4)** wird durch einen weißen Würfel dargestellt. Die Kameras sind so

angebracht, dass der Roboter selbst nicht im Bild zu sehen ist. Der Würfel ist für den Bediener gedacht, der die Szene aus einem Blickwinkel hinter dem Roboter steuert. Abbildung 4.2 zeigt ein Bild, welches aus diesem Blickwinkel aufgenommen worden ist. Der Roboter lässt sich mit den Tasten W, A, S, D (vorwärts, links, rückwärts, rechts) oder mit einem Pad<sup>3</sup> mit Analogsticks steuern. Mit der Tastensteuerung ist nur eine feste Geschwindigkeit möglich. Die Steuerbefehle für den Roboter werden als Geschwindigkeit (gerade aus) und Drehrate interpretiert. Diese führen dann, in jedem Simulationsschritt zu einer Positionsänderung. Es wird erst eine Drehung um die Hälfte der Winkeländerung durchgeführt. Anschließend wird in die neuer Richtung geradeaus die Streckenänderung zurück gelegt. Mit einer zweiten Drehung bis zur vollen Winkeländerung wird die Bewegung abgeschlossen. Die Position des Roboters wird relativ zum Bühnenkoordinatensystem in x- und y-Werten ausgedrückt. Im Roboterkoordinatensystem zeigt die x-Achse immer in Fahrtrichtung des Roboters, die z-Achse zeigt nach oben und mit der y-Achse ergibt sich ein Rechtssystem. Der Ursprung dieses Systems ist mittig zwischen den Rädern auf Bodenhöhe. Die Orientierung des Robotermodells wird als Winkel zwischen den x-Achsen von Roboter- und Bühnenkoordinatensystem ausgedrückt.

**Besucher (5)** werden mit 400 x 400 x 1800 mm Quadern dargestellt. Damit sie für den Bediener besser in der Szene zu erkennen sind, wurden sie grün gefärbt. Sie bewegen sich nicht, sondern stehen an vorher festgelegten Positionen. Vor einer Simulation wird die Anzahl der Besucher eingestellt, die auf der Bühne stehen sollen. Dabei gibt es 25 mögliche Positionen aus denen dann die gewünschte Anzahl zufällig gezogen wird. Sie sollen mögliche Verdeckungen im Bildbereich des Roboters darstellen. Damit soll untersucht werden, wie gut der Algorithmus mit teilweise verdeckten Code-Bereichen umgehen kann.

**Partikel (6)** werden zur Veranschaulichung und zu debugging Zwecken visualisiert. Sie werden durch rote kleine spitze Dreiecke dargestellt. Der spitze Winkel zeigt dabei die Orientierung an. Sie befinden sich nur auf dem Boden und beeinträchtigen die Bildverarbeitung deshalb nicht.

### 4.3 Messen in der Simulation

Die Simulation soll, neben der Visualisierung, Messungen liefern um den Lokalisationsalgorithmus testen zu können. Im Gegensatz zu Messungen an realen Expe-

<sup>3</sup>PlayStation 3 Wireless Sixaxis Controller



rimenten gibt es in der Simulation die Möglichkeit, alle das Messergebnis beeinflussenden Faktoren festlegen zu können. Beispielsweise können systematische Abweichungen bei Messungen in der Simulation definiert werden. Ähnlich verhält es sich mit statistischen Abweichungen. Es lassen sich also schnell die Messunsicherheiten der simulierten Vorgänge anpassen. Beim Debugging und Funktionstest des Lokalisationsalgorithmus wurde die Unsicherheit zum Beispiel zeitweise entfernt.

#### 4.3.1 Messwerte der Encoder

Wie beim Robotermodell in Abschnitt 4.2 beschrieben, wird in der Simulation dessen x/y-Koordinate sowie der Winkel zur x-Achse als Repräsentation der Pose verwendet. Aus den Positions- ( $\Delta s$ ) und Orientierungsänderungen ( $\Delta\psi$ ), in jedem Simulationsschritt, werden Drehwinkeländerungen ( $\Delta\alpha_{r/l}$ ) der beiden Räder berechnet:

$$\Delta\alpha_{rechts} = \frac{\Delta s + \Delta\psi \cdot D_r}{R_r} \quad (4.1)$$

$$\Delta\alpha_{links} = \frac{\Delta s - \Delta\psi \cdot D_l}{R_l} \quad (4.2)$$

mit Abstand  $D_{r/l}$  des Rades von der Mitte der Achse und Radradius  $R_{rad}$ . Die Drehwinkeländerungen werden aufsummiert um die Radstellungen zu speichern:

$$\alpha = \alpha + \Delta\alpha \quad (4.3)$$

Aus diesen Winkelstellungen<sup>4</sup> der Räder wird ein Wert für die Encoder abgeleitet und auf ganze Impulse gerundet:

$$I_{rechts} = \alpha_{rechts} \cdot \frac{g \gamma}{2\pi} \quad (4.4)$$

$$I_{links} = \alpha_{links} \cdot \frac{g \gamma}{2\pi} \quad (4.5)$$

mit Getriebeübersetzung:  $g$  und Encoder-Auflösung(pro Umdrehung):  $\gamma$

#### 4.3.2 Messabweichung der Encoder

Es können drei verschiedene Typen von Messabweichungen simuliert werden:

Eine **systematische Abweichung** durch einen ungenau bekannten Radradius. Dies führt zu einem sich akkumulierenden Fehler in der Gefahrenen Strecke und der Orientierung. In der Simulation wurde diese Art Unsicherheit durch einen veränderten

<sup>4</sup>Die Winkelstellung der Räder wird nur numerisch simuliert und ist am Modell nicht sichtbar.

Radradius  $R_{r/l}$  erzeugt. Für beide Räder wird vor jedem Simulationslauf in einem Fehlerintervall der Radius leicht verändert.

$$R_{r/l} = R_{Ma} + R_{Ma} \cdot \sigma_R \cdot RandomGaussian() \quad (4.6)$$

Mit  $\sigma_R$  lässt sich einstellen, wie stark die Abweichung ist. Je stärker die Radien sich unterscheiden, desto stärker scheint der Roboter bei geradeaus Fahrt eine lichte Kurve zu fahren. Diese Art Messabweichung ist über die Dauer eine Simulation konstant, aber für jeden Simulationslauf zufällig.

Eine **systematische Abweichung** die nur bei Drehungen auftritt. Dies ist typischerweise die dominante Fehlerquelle bei radgetriebenen Robotern. Bei einer Drehung ist der Auflagepunkt der Räder nicht bekannt, da der innen liegende Teil des Rades sich langsamer drehen müsste als der äußere. Dies führt bei einer Drehung dazu, dass der Abstand des Rades zur Drehachse nicht genau bekannt ist. In der Simulation wird daher dieser Abstand  $D_{r/l}$  über die Breite  $W_{r/l}$  der Räder zufällig bestimmt.

$$D_{r/l} = \frac{K}{2} + W_{r/l} \cdot 0,5 \cdot RandomGaussian() \quad (4.7)$$

mit Spurbreite  $K$  von Radmitte zu Radmitte.

Dieser Abstand müsste für jede Drehung neu bestimmt werden. Zum Testen der Lokalisation reicht es aber aus, wenn dies nur einmal zu Beginn einer Simulation geschieht. Dadurch treten bei Drehungen Messabweichungen auf, die zwar über einen Simulationslauf konstant und damit systematisch sind, aber die Lokalisierung genauso erschweren wie zufällige Abstände während der Laufzeit.

Eine **zufällige Abweichung** bei den Encoder-Messwerten soll ein mögliches Spiel in Kupplung oder Getriebe simulieren. Dabei wird zu dem akkumulierten Encoder-Wert eines Rades ein Gaußsches Rauschen  $err$  addiert, welches proportional zur letzten Winkeländerung  $\Delta\psi$  ist. Ist diese bei Stillstand gleich Null, so wird nur ein schwaches Grundrauschen addiert.

$$err = (\Delta\psi + RobotMaxSpeed \cdot 0.01) \cdot psi2I \cdot \sigma_I \cdot RandomGaussian() \quad (4.8)$$

mit einem Umrechnungsfaktor  $psi2I$  der hier zur Abkürzung verwendet wird. Das  $\sigma_I$  ist ein Koeffizient, mit dem sich die Stärke des Rauschens einstellen lässt und  $(RobotMaxSpeed \cdot 0.01)$  ist für eine Grundrauschen zuständig, das proportional zur eingestellten Roboter-Maximalgeschwindigkeit ist.

### 4.3.3 Bilder der Kamera


Die Kamera des Roboters wird in der Simulation nicht als Modell angezeigt. Sondern lediglich durch ein Objekt der Klasse `osgViewer::View` implementiert. Um einer echten Kamera möglichst nah zu kommen, wurde die Auflösung sowie der Öffnungswinkel der am Roboter verbauten Kamera in der Simulation nachempfunden. Die Auflösung der Bilder ist mit 1280 x 720 Pixeln im 16:9 Format. Der Horizontale Öffnungswinkel beträgt 74 Grad. Die verwendete OSG Bibliothek setzt auf OpenGL auf und nutzt deshalb auch die dort verwendeten Funktionen zur Perspektivischen Projektion. In Abbildung 4.3 ist zu sehen, wie diese in OpenGL beschrieben wird. Ein Pyramiden Stumpf begrenzt dabei ein Volumen, in dem alle sichtbaren Objekte liegen. Dieser Pyramidenstumpf wird auch **frustum** genannt. Seine Eigenschaften werden üblicher Weise in einer Projektionsmatrix zusammen gefasst, die sich direkt, oder über Hilfsfunktionen definieren lässt. Die verwendete Funktion benötigt folgende Parameter:

**fovy** Gibt den vertikalen Öffnungswinkel in Grad an.

**aspect** Gibt das Verhältnis zwischen horizontalem und vertikalem Öffnungswinkel an. Es sollte gleich dem Seitenverhältnis der Bildauflösung gewählt werden, um keine Verzerrungen zu erzeugen. (Breite/Höhe)

**zNear** Gibt den Abstand zwischen Betrachter und Projektionsfläche an. Sie wird auch zum clipping verwendet. (immer positiv)

**zFar** Gibt den Abstand zur hinteren clipping Ebene an. Alles was weiter als diese Ebene entfernt ist, wird nicht mit auf das Bild projiziert. (immer positiv)



quelle: [https://commons.wikimedia.org/wiki/File:Field\\_of\\_view\\_angle\\_in\\_view\\_frustum.png](https://commons.wikimedia.org/wiki/File:Field_of_view_angle_in_view_frustum.png)

Abbildung 4.3: OpenGL beschreibt die perspektivische Projektion mit Hilfe eines **frustum**

OpenGL projiziert zunächst auf eine normalisierte Bildebene. Aus dieser normalisierten Darstellung muss mittels einer Viewporttransformation in die Bildschirmkoordinaten (Pixel) umgerechnet werden. Der Viewport ist dabei der Bildschirmbereich, auf den das gerenderte Bild angezeigt wird. Mit OSG lässt sich der Viewport für eine Kamera mit der gewünschten Auflösung (Höhe, Breite) und einem Ursprung setzen. Die Matrix für die Viewporttransformation heißt in OSG `windowMatrix`, und wird automatisch aus dem gesetzten Viewport berechnet.

Die Bilder der Roboter Kamera werden nicht auf dem Bildschirm angezeigt, sondern in einen Buffer geschrieben und von dort in ein für OpenCV nutzbares Format kopiert. In dieser Form werden die Bilder auf der Festplatte gespeichert und an die Lokalisation als Messupdate gegeben.

## 4.4 Einstellungen

In der Simulationssoftware lassen sich bestimmte Parameter verändern, um ihr Verhalten zu definieren. Hier soll kurz zusammen gefasst werden welche Parameter es gibt, und was sie beeinflussen. In Klammern steht der voreingestellte Default-Wert.

**picture path** (<path>) Die Bilder die während eines Simulationslaufes von der Kamera gemacht werden, werden an diese Stelle gespeichert. Sie sind aufsteigend nummeriert, beginnend mit "0000.jpg"

**datafile name** ("locaDatafile.txt") Der name der Datei in der die Rohdaten eines Simulationslaufes gespeichert werden. Sie enthält Encoder-Werte, echte Roboterpose, geschätzte Roboterpose, Varianz Roboterpose und den Pfad zum Bild das zu den Messwerten gehört. Die Werte werden in jedem Simulationsschritt geschrieben.

**takepicture intervall** (3000) Zeit in Millisekunden zwischen zwei Kamerabildern. Dabei wird **loop target time** verwendet um zu bestimmen wie viele Simulationsschritte der Zeitangabe entsprechen.

**loop target time** (33333) Zeit in Mikrosekunden die einem Simulationsschritt entspricht. Der default wert entspricht 30 Schritte pro Sekunde.

**crowd size** (0) Stellt ein wie viele Personen auf der Bühne sein sollen. Mögliche sind 0 bis 23 Personen.

**particle visibility ratio** (1) Dies stellt ein wie viele Partikel visualisiert werden. Es beeinflusst die Simulation nicht und dient nur dem Bediener um das Partikelverhalten sehen zu können. Der Wert ist als Teiler zu verstehen, 1 bedeutet alle Partikel werden visualisiert während 10 nur ein Zehntel darstellt.

**sys error on** (true) Mit diesem Flag kann der Systematische Fehler ein- oder ausgeschaltet werden.

**camera picture width** (1280) Gibt die Bildauflösung der Simulierten Kamera an.

**camera picture height** (720) Gibt die Bildauflösung der Simulierten Kamera an.

**field of view horizontal** (74) Dies stellt den horizontalen Öffnungswinkel der Kamera ein.

**blind mode on** (false) Dieses Flag deaktiviert zwei Fenster der Simulation mit denen ein Bediener die Vorgänge beobachten kann. Dies ist sinnvoll, wenn automatisiert viele Simulationsdurchläufe durchgeführt werden sollen.

**robParameter.kDistanceLeftWheel** (0.35) Abstand linkes Rad zum Robotermitte

**robParameter.kDistanceRightWheel** (0.35) Abstand rechtes Rad zum Robotermitte

**robParameter.kLeftWheelWidth** (0.03) Dicke linkes Rad

**robParameter.kRightWheelWidth** (0.03) Dicke rechtes Rad

**robParameter.kRadiusWheelRight** (0.08) Rechter Radradius

**robParameter.kRadiusWheelLeft** (0.08) Linker Radradius

**robParameter.kImpulePerTurn** (2000) Encoder-Auflösung pro Umdrehung

**robParameter.kTransmissionKoefficient** (14.5) Faktor zwischen Raddrehung und Motorwelle

**robParameter.kPsiSpeed** (0.05) Winkeländerung bei Drehung pro Schritt

**robParameter.kSigmaIncrement** (0.05) Koeffizient für gaußsches Rauschen der Encoder-Werte

**robParameter.kSigmaRadius** (0.003) Koeffizient für systematischen Radiusabweichung.

**robParameter.kSpeed** (0.05) Strecke die pro Simulationsschritt zurückgelegt wird.

## 5 Versuche in der Simulation

Die Versuche in diesem Kapitel sollen helfen das entwickelte Verfahren zu bewerten. Zunächst wird eine Versuch beschrieben, in dem das Messmodell des Partikel-Filters untersucht wurde. Danach wird anhand von verschiedenen Fahrkurven das Verhalten bei unterschiedlichen Bildaufnahmefrequenzen betrachtet, sowie der Einfluss von Personen auf der Bühne beurteilt.

Wenn nicht anders angegeben, werden folgende Einstellungen für Simulation und Lokalisation verwendet:

**test1** hallo

**test2** hallo2

**test3** moin

**test4** moin4

### 5.1 Versuche zur Genauigkeit des Messmodells

In einer ersten Versuchsreihe, soll die Genauigkeit des im Partikelfilter verwendeten Messmodells untersucht werden. Dafür soll zu einem gegebenen Bild möglichst der gesamte Zustandsraum mit dem in Kapitel 3.2.3 beschriebenen Verfahren bewertet werden. Die Anzahl der Punkte im Zustandsraum, die einen hohen Score erhalten, lässt darauf schließen wie genau die Zuordnung zwischen Bild und Pose funktioniert. Im ersten Durchlauf soll zunächst grob der gesamte Raum abgesucht werden. Er soll einen Überblick geben, wo Antworten liegen, die dann in weiteren Durchläufen genauer abgetastet werden können.

Für die Versuchsreihe wird der Zustandsraum zunächst grob in 5 cm Rasterschritten durchsucht. Dabei wird die Orientierung in 0,05 Rad ( $2,86^\circ$ ) Schritte aufgeteilt. In drei Schleifen wird so der Zustandsraum durchlaufen. Als Messung wurde ein am Ursprung ( $x = 0, y = 0, \psi = 0$ ) aufgenommenes Bild verwendet. Für die Darstellung in Abbildung 5.1 oben, wurden Höhenlinien der Messantwort eingezeichnet. Dabei wurde jeweils nur die stärkste Antwort an einer Position über alle Winkel gewählt. Bei einem Zweiten Durchlauf wurde die Positionsraasterung auf 1 cm Schritte und die




Abbildung 5.1: Antwort des Messmodells zu einem Bild an der rot markierten Position  
oben: 5 cm Raster 3° Schritte unten: 1 cm Raster 0.3° Schritte




Winkelschritte auf 0,005 Rad ( $0.28^\circ$ ) verkleinert. Zu sehen ist dies auf Abbildung 5.1 unten. Um den Einfluss des Winkels darzustellen wurde in Abbildung 5.2 die Antwort entlang einer Linie mit  $x = 0.0$  geplottet.

In Abbildung 5.1 oben ist der Zustandsraum der Position dargestellt. Die Orientierung konnte in dieser Abbildung nicht gezeigt werden. Die Lichtwände wurden als schwarze Balken kenntlich gemacht. Der rote Kreis zeigt die Pose des Roboters als das Bild aufgenommen wurde. Eine Antwort des Messmodells ist nur um die diese Position zu sehen, in dem Rest des Zustandsraumes (Bühne) gab es keine signifikante Antwort. Auf dem Bild darunter sieht man einen Vergrößerten Ausschnitt um die Roboterposition. Hier fällt auf, dass die Häufung leicht schräg liegt. Der Grund dafür ist vermutlich, dass die Lichtwand auf der das Muster abgebildet ist, nicht zentral vor dem Roboter steht, sondern in Y-Richtung verschoben ist. Die Häufung der Antworten streut vor allem entlang der Y-Achse, dies entspricht einer seitlichen Verschiebung des Roboters entlang dieser Achse bei gleichzeitiger Drehung. Dabei sind innerhalb von  $\pm 30\text{ cm}$  immer noch Scores größer als 0,8 möglich. Entlang der X-Achse ist eine Streuung zwischen  $+15$  und  $-10\text{ cm}$  zu erkennen. Durch die Höhenlinien ist zu erkennen, dass entlang der x-Achse der Score eine große Steigung hat. Dies führt zu einer relativ scharfen Kante in dieser Richtung. Auf der y-Achse dagegen, ist die Steigung schwächer, dadurch bildet sich keine scharfe Kante. Aus Abbildung 5.2 lässt sich entnehmen, dass bei einer Verschiebung entlang der Y-Achse eine Drehung des Roboters nötig ist, um eine Pose zu erhalten die einen guten Score erhält.

## 5.2 Verwendete Fahrkurven

Es sind vier verschiedene Fahrkurven für die folgenden zwei Versuche verwendet worden. An dieser Stelle soll kurz auf Besonderheiten hingewiesen werden, die für diese Kurven beobachtet wurden. Für alle Kurven gilt, dass sie in der Mitte der Bühne beginnen, und die Lokalisation mit der Startposition initialisiert ist. Die Versuche beziehen sich somit nur auf das Pose Tracking der Lokalisation. Auf den Abbildungen 5.3 und 5.4 sind die Lichtwände zur Orientierung als schwarze Rechtecke in die Diagramme eingezeichnet worden. Bei den Simulationen für diese Fahrkurven wurden alle 1500 ms Bilder der Kamera ausgewertet. Die blauen Ellipsen sind die  $3\sigma$  Vertrauensbereiche um die geschätzte Position des Roboters. Sie wurden für einzelne Stichproben eingezeichnet.

**Loop Anticlockwise** Ist eine Fahrt entlang der äußeren Kanten der Bühne, dabei

Abbildung 5.2: Antwort des Messmodells bei  $x=0.0$ 

fährt der Roboter gegen den Uhrzeigersinn. Die Lichtwände stehen nicht auf der Ganzen Länge der Bühne, sondern immer versetzt. Dies führt bei dieser Fahrtrichtung dazu, dass die Lichtwände seltener im Bild sichtbar sind. Es müssten weniger Bit-Musterpunkte im Bild zu sehen sein, als bei der Fahrt im Uhrzeigersinn. Aber genug um einen Score zu bilden. Zu sehen auf Abbildung 5.3 oben auf Seite 42. Es ist zu erkennen, dass auch entlang der offenen Seite die Unsicherheit groß bleibt, obwohl auf eine Lichtwände zu gefahren wird. Dies liegt vermutlich an der Versetzt aufgestellten Wand. Der Roboter fährt hier auf ein offenes Stück zu und die Mess-Updates reichen nicht um die Position genauer eingrenzen zu können.

**Loop Clockwise** Fährt die gleiche Strecke von **Loop Anticlockwise** entlang, nur im Uhrzeigersinn. Die Kamera des Roboters ist die meiste Zeit auf mindestens eine Lichtwand gerichtet. Nur wenn er auf die offene Seite zu fährt erhält er kein auswertbares Messupdate. Zu sehen auf Abbildung 5.3 unten auf Seite 42. Die Unsicherheit der Position nimmt auf dem Stück zur offenen Seite hin deutlich

zu, sobald wieder eine Lichtwand von der Kamera erfasst wird, nimmt sie wieder ab.

**Schlangenlinien** Bei dieser Fahrt fährt der Roboter mehrere male zwischen der Seite ohne Lichtwand und der ihr gegenüber liegenden Lichtwand hin und her. Dabei fährt er in Schlangenlinien die Bühne ab. In dieser Fahrkurve sind besonders viele scharfe Kurve enthalten. Des weiteren wird immer wieder auf die offene Seite zu gefahren, so dass es zeitweise keine auswertbaren Bilder gibt. Zu sehen auf Abbildung 5.4 oben auf Seite 44. Besonders stark wird die Unsicherheit wenn der Roboter oben links im Diagramm dicht an der Lichtwand entlang und auf die offene Seite zu fährt. Es ist außerdem gut zu erkennen, wie die Unsicherheit größer wird, wenn der Roboter in negativer x-Richtung auf die offene Seite zu fährt und wieder kleiner wird, wenn er in positiver x-Richtung auf die Lichtwand zu fährt.

**Ellipse** Eine schräge Ellipse die um den Mittelpunkt liegt. Dabei fährt der Roboter etwa die Hälfte der Strecke auf zwei Lichtwände zu und die andere Hälfte auf die Ecke der Bühne in der keine Lichtwände stehen. Während er auf die offene Seite zu fährt, sieht er zeitweise keine Lichtwand um einen verwertbare Messung zu erhalten. Zu sehen auf Abbildung 5.4 unten auf Seite 44. Entsprechend verhält sich die Unsicherheit auf diesem Abschnitt. Sie wird größer, bis wieder eine Lichtwand in das Gesichtsfeld der Kamera kommt. Auf der Fahrt auf die Lichtwände zu bleibt die Unsicherheit klein.

### 5.3 Versuche zur Bildaufnahmefrequenz

Es soll untersucht werden in welchen Intervallen Bilder benötigt werden, wie stark der Einfluss der Fahrkurve darauf ist, und welche Faktoren die Bildaufnahmefrequenz beeinflussen können. Dazu werden die vier beschriebenen Fahrkurven eingesetzt. Sie werden in einem Simulationslauf dreimal abgefahren. Bei diesem Vorgang wird der Abstand zwischen der wahren und der vom Filter geschätzten Position des Roboters errechnet und über die Simulationsdauer ein Mittelwert  $\hat{d}$  bestimmt.

$$\hat{d} = \frac{1}{n} \sum_{i=0}^n \sqrt{(x_i - x_{true_i})^2 + (y_i - y_{true_i})^2} \quad (5.1)$$

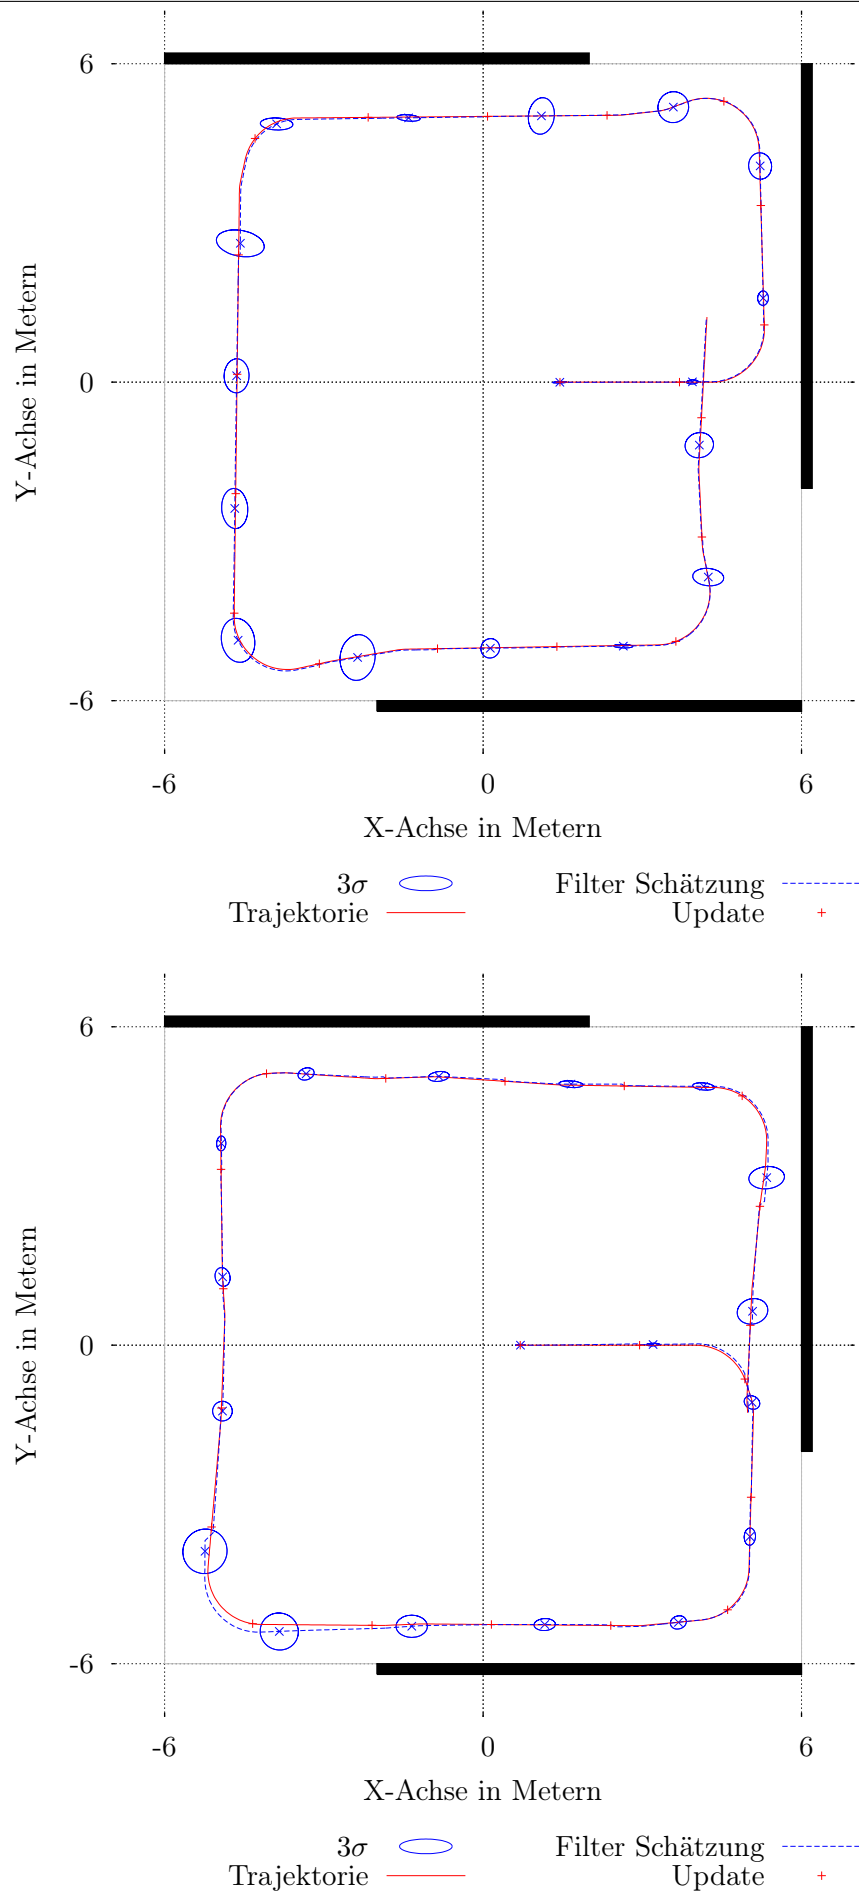


Abbildung 5.3: Fahrkurven oben Loop Anticlockwise, und unten Loop Clockwise

Um zusätzlich noch ein Maß für die Genauigkeit der geschätzten Position zu haben, wird der Mittelwert der großen Achse der Unsicherheits-Ellipsen gebildet:

$$\hat{a} = \frac{1}{n} \sum_{i=0}^n a_i \quad (5.2)$$

Jeder Simulationsdurchlauf arbeitet mit zufälligen systematischen Messabweichungen. Aus diesem Grund werden 15 Simulationsdurchläufe bei gleichen Einstellungen durchgeführt und über deren Ergebnisse gemittelt. Es wurden vier verschiedene Perioden für die Zeit zwischen zwei Bildern festgelegt: 500, 1000, 2000 und 4000 *ms*. Für jeden dieser Schritte wurde jede Fahrkurve damit 15 mal simuliert.

Die Ergebnisse sind in Abbildung 5.5 und 5.6 zu sehen. Für alle vier Fahrkurven lässt sich beobachten, dass sich bei sinkender Bildaufnahmefrequenz ein Anstieg des mittleren Abstandes zur tatsächlich gefahrenen Trajektorie ergibt. Für die Fahrkurven **Ellipse** und **Loop Anticlockwise** ist der Anstieg zwischen 500 und 2000 *ms* in etwa linear und macht ab 4000 *ms* einen Sprung. Für die **Schlangenlinien** ist ein Sprung schon zwischen 1000 und 2000 *ms* zu sehen, mit einem weiteren zwischen 2000 und 4000 *ms*. Bei **Loop Clockwise** hingegen ist kein signifikanter Sprung zu erkennen.

Auch der mittlere lange Durchmesser der Ellipse wächst bei sinkender Bildaufnahmefrequenz für alle Fahrkurven. Hier ist jedoch kein so signifikanter Sprung zu beobachten wie beim Abstand. Es lässt sich nur ein unterschiedlich starker Anstieg im Durchmesser für die Fahrkurven ausmachen.

**Loop Clockwise** hat den geringsten Anstieg und hat von allen Fahrkurven, bei den untersuchten Bildaufnahmefrequenzen, den kleinsten mittleren Durchmesser der Unsicherheits-Ellipse.

**Loop Anticlockwise** hat durchgehend den zweit kleinsten Durchmesser und einen Anstieg der nur knapp über **Loop Clockwise** liegt.

**Ellipse** liefert bei 500 und 1000 *ms* den größten Durchmesser. Der Anstieg ist dabei aber nicht so stark wie bei den **Schlangenlinien**.

**Schlangenlinien** sie zeigen die größte Zunahme beim Durchmesser. Während sie zwischen 500 und 1000 *ms* an zweiter Stelle liegen, liefern sie zwischen 2000 und 4000 *ms* den größten Durchmesser.

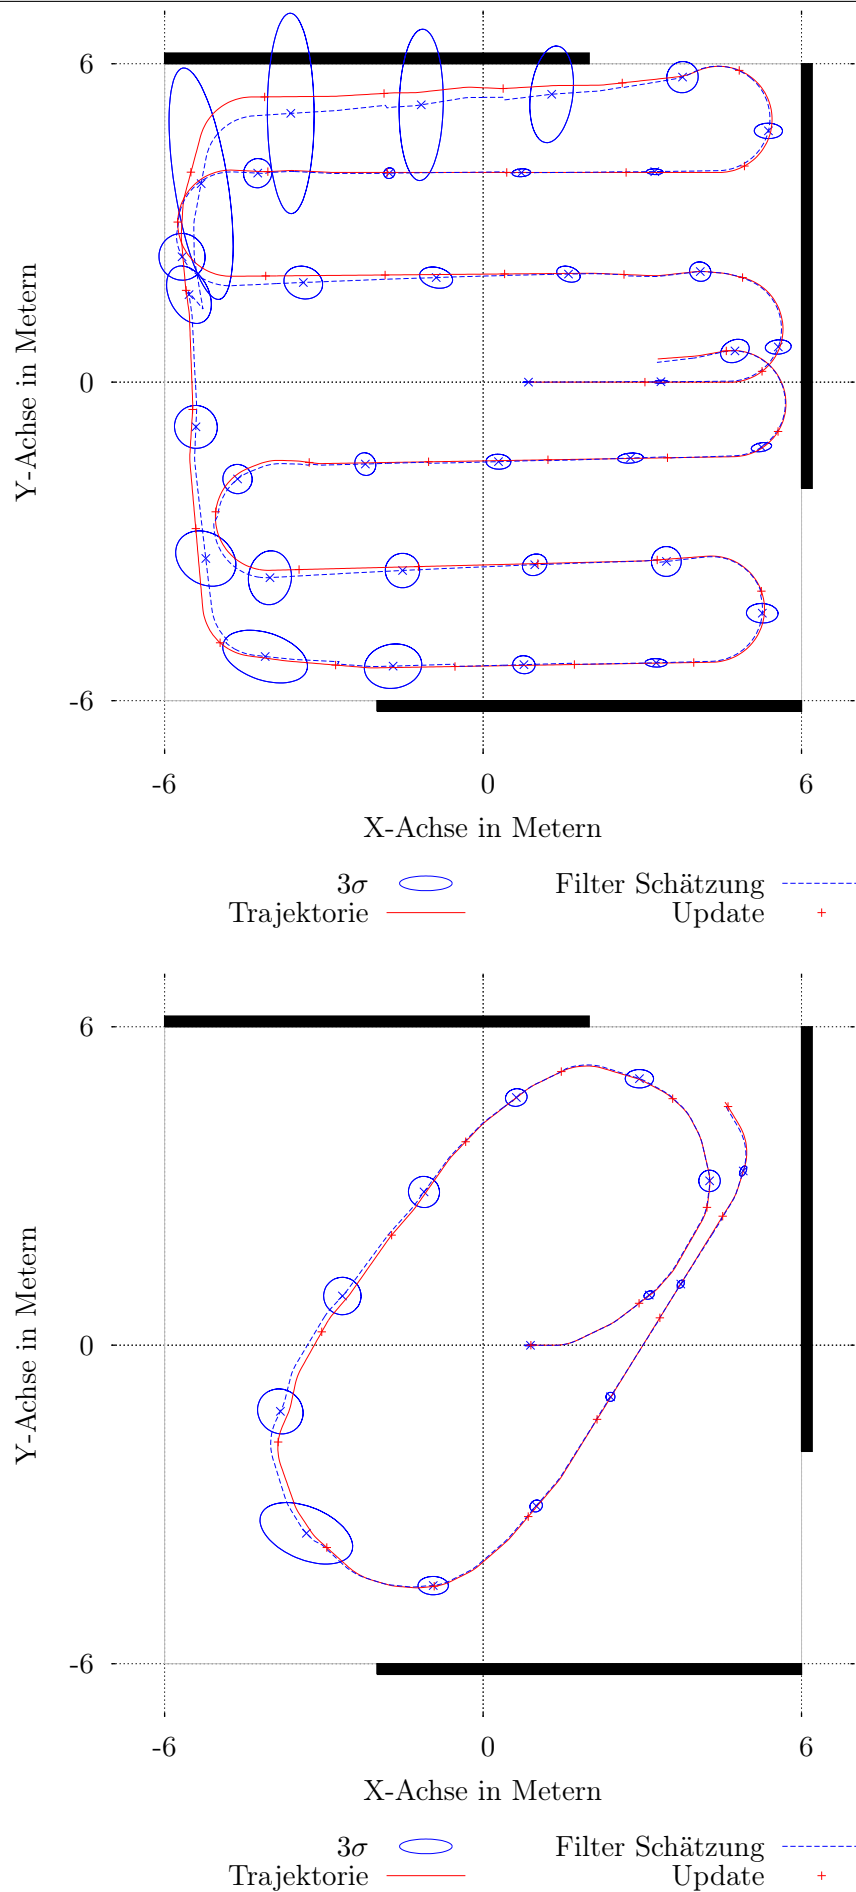


Abbildung 5.4: Fahrkurven oben Schlangenlinien, unten schräge Ellipse





Abbildung 5.5: Gemittelter Abstand von der Fahrkurve über verschiedene Bildaufnahme-frequenzen mit vier verschiedenen Fahrkurven.

## 5.4 Versuche zum Einfluss von Menschen auf der Bühne

In diesem Versuch soll untersucht werden, wie stark Menschen auf der Bühne die Lokalisation mit dem hier vorgestellten Verfahren stören. Dabei geht es im wesentlichen darum, dass Menschen im Bild stehen und so die Bit-Muster ganz oder teilweise verdecken. Wie bei den Versuchen zur Bildaufnahmefrequenz wird auch hier der mittlere Abstand zur wahren Roboterposition verwendet. Als Fahrkurven werden ebenfalls die in Abschnitt 5.2 beschriebenen verwendet. Die Art der Durchführung des Versuches wird nicht verändert. Es wird jedoch anstatt des Zeitintervalls die Anzahl der Personen auf der Bühne geändert (3,9,15,21). Das Zeitintervall für die Bildaufnahme wurde fest auf 1500 *ms* eingestellt.

Es gibt 23 festgelegte Positionen für Personen auf der Bühne. Aus diesen wird bei jedem Simulationslauf zufällig die






Abbildung 5.6: Gemittelter langer Durchmesser der Unsicherheits-Ellipse über verschiedene Bildaufnahmefrequenzen mit vier verschiedenen Fahrkurven.

benötigte Anzahl ermittelt. Auf Abbildung 5.7 sind die möglichen Positionen der Personen zu sehen. Wie in Abschnitt 4.2 beschrieben sind die Personen 1800 mm hoch und 400 mm breit. Es ist davon auszugehen, dass je mehr Personen sich auf der Bühne befinden, es umso häufiger vorkommt, dass sie das Bit-Muster teilweise oder ganz verdecken. Bei einer hohen Personendichte sollte demnach der mittlere Abstand von der wahren Position größer werden.



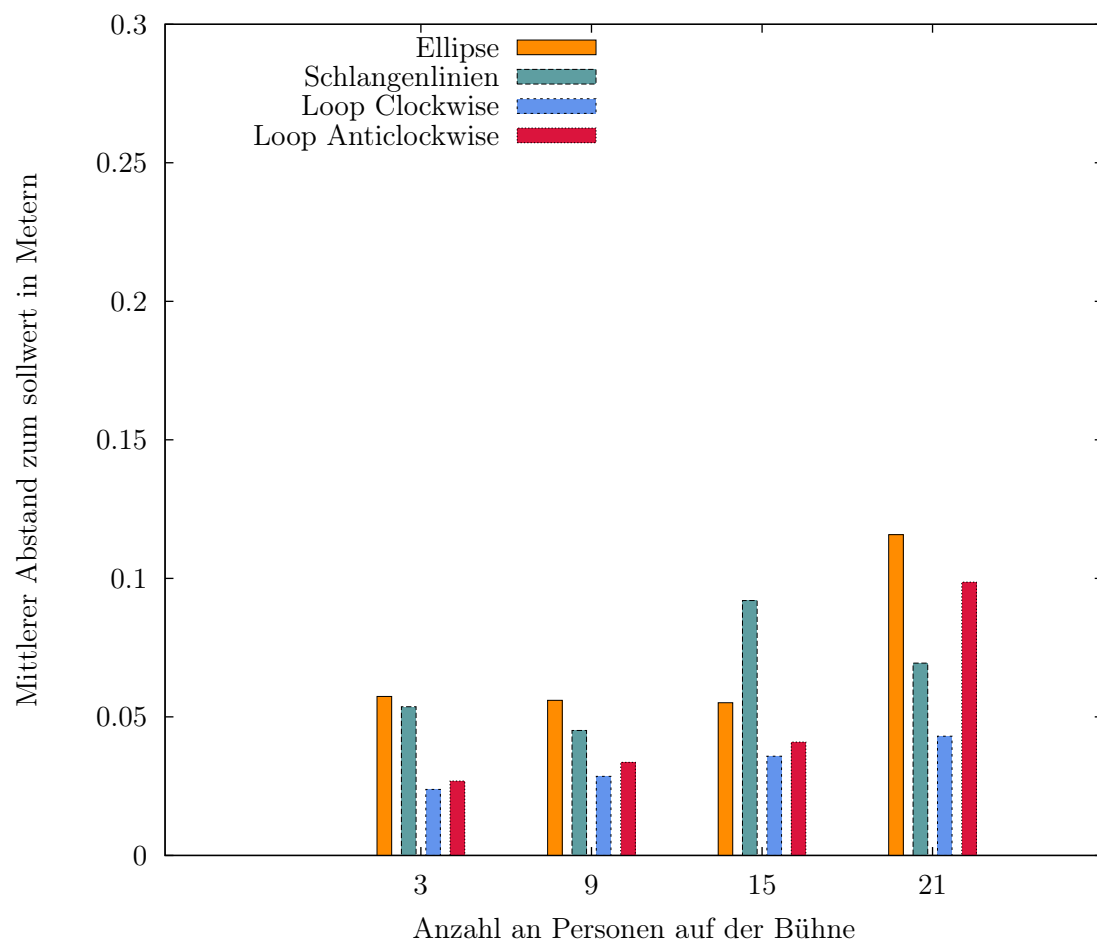


Abbildung 5.8: toller text



## 6 Fazit und Ausblick

## A Abkürzungsverzeichnis

**CDT** *C/C++ Development Tools*

**OSG** *Open Scene Graph*

**BBM** *Beobachter der Bediener von Maschinen*

**SLAM** *Simultaneous Localization and Mapping*

**MCL** *Monte Carlo Localization*



## B Literaturverzeichnis

- [Ha et al., 2012] Ha, X. V., Ha, C., and Lee, J. (2012). *Intelligent Computing Technology: 8th International Conference, ICIC 2012, Huangshan, China, July 25-29, 2012. Proceedings: Trajectory Estimation of a Tracked Mobile Robot Using the Sigma-Point Kalman Filter with an IMU and Optical Encoder*, volume 7389 of *Lecture Notes in Computer Science*. Berlin, Heidelberg.
- [Hertzberg et al., 2012] Hertzberg, J., Lingemann, K., and Nüchter, A. (2012). *Mobile Roboter: eine Einführung aus Sicht der Informatik*. eXamen.press. Springer Vieweg, Berlin [u.a.]. X, 389 S. : zahlr. Ill. und graph. Darst.
- [Jähne, 2005] Jähne, B. (2005). *Digitale Bildverarbeitung*. Springer-Verlag Berlin Heidelberg, Berlin, Heidelberg, 6., überarbeitete und erweiterte auflage edition. Online-Ressource : v.: digital.
- [Seco et al., 2009] Seco, F., Jiménez, A. R., Prieto, C., Roa, J., and Koutsou, K. (2009). A survey of mathematical methods for indoor localization. In *Intelligent Signal Processing, 2009. WISP 2009. IEEE International Symposium on*, pages 9–14. IEEE.
- [Thrun, 2002] Thrun, S. (2002). Particle filters in robotics. In *Proceedings of the Eighteenth conference on Uncertainty in artificial intelligence, UAI'02*, pages 511–518, San Francisco, CA, USA. Morgan Kaufmann Publishers Inc.
- [Thrun et al., 2006] Thrun, S., Fox, D., and Burgard, W. (2006). *Probabilistic robotics*. Intelligent robotics and autonomous agents. MIT Press, Cambridge, Mass. [u.a.]. XX, 647 S. : Ill., graph. Darst.
- [Tönnies, 2005] Tönnies, K. D. (2005). *Grundlagen der Bildverarbeitung*. Informatik. Pearson Studium, München. Online-Ressource.



## C Anhang



**Code 93 bar code**

ID	Character	Widths	Binary	ID	Character	Widths	Binary
0	0	131112	100010100	28	S	211122	110101100
1	1	111213	101001000	29	T	211221	110100110
2	2	111312	101000100	30	U	221121	110010110
3	3	111411	101000010	31	V	222111	110011010
4	4	121113	100101000	32	W	112122	101101100
5	5	121212	100100100	33	X	112221	101100110
6	6	121311	100100010	34	Y	122121	100110110
7	7	111114	101010000	35	Z	123111	100111010
8	8	131211	100010010	36	-	121131	100101110
9	9	141111	100001010	37	.	311112	111010100
10	A	211113	110101000	38	SPACE	311211	111010010
11	B	211212	110100100	39	\$	321111	111001010
12	C	211311	110100010	40	/	112131	101101110
13	D	221112	110010100	41	+	113121	101110110
14	E	221211	110010010	42	%	211131	110101110
15	F	231111	110001010	43	(\$)	121221	100100110
16	G	112113	101101000	44	(%)	312111	111011010
17	H	112212	101100100	45	(/)	311121	111010110
18	I	112311	101100010	46	(+)	122211	100110010
19	J	122112	100110100	Start/Stop *		111141	101011110
20	K	132111	100011010	(Reverse stop)		114111	101111010
21	L	111123	101011000	Unused		411111	111101010
22	M	111222	101001100			111132	101011100
23	N	111321	101000110			111231	101001110
24	O	121122	100101100			113112	101110100
25	P	131121	100010110			113211	101110010
26	Q	212112	110110100			213111	110111010
27	R	212211	110110010			212121	110110110

Abbildung C.1: code 93, Quelle: Wikipedia